

每日生醫新聞報告

技術導讀與學習地圖



產出日期：2025/10/30

目錄

1. 生理訊號 / 醫療裝置-----
2. NeuroPilot：一種即時腦機介面系統以提升學生在線學習的專注力
3. MoPFormer：用於可穿戴感測器活動識別的運動基元變壓器
4. 高斯融合：基於高斯的多感測器融合技術，用於端到端自動駕駛
5. PULSE：從皮膚電活動到低成本感測器的壓力監測知識轉移
6. NeuroPilot：即時腦機介面系統提升學生在線學習專注力
7. 神經科學 / 心理學-----
8. 物體綁定是否自然出現在大型預訓練視覺變壓器中？
9. 多模態夢境：基於全球工作空間的世界模型強化學習方法
10. NOBLE -- 神經運算符與生物信息潛在嵌入，用於捕捉生物神經元模型中的實驗變異性
11. 中風病灶分割在臨床工作流程中的應用：一個模組化、輕量化且可部署的工具
12. 無監督偵測中風後腦部異常
13. AI / 數據分析-----
14. 基因型-表現型整合：透過機器學習和個人化基因調控網絡預測癌症轉移
15. 腸道決策基於肝臟：利用放射組學提升大腸癌篩檢
16. 機器學習方法在抗體屬性預測中的應用：結構數據的解釋性
17. 精準醫療中的N-of-1人工智慧生態系統
18. Pearl：一個將每個原子放置在正確位置的基礎模型
19. 產業趨勢 / 法規-----
20. CFM-GP：統一條件流匹配以學習跨細胞類型的基因擾動
21. 因果感知生成對抗網絡與強化學習
22. CFM-GP：統一條件流匹配學習跨細胞類型基因擾動
23. CMS批准腎臟去神經術的全國覆蓋，惠及美敦力和Recor
24. 羅氏承諾向中國生技公司投資10億美元，用於開發臨床前階段的雙特異性抗體治療COPD
25. 生科基礎研究-----
26. PanDelos-plus：在泛基因組分析中計算序列同源性的平行算法
27. 將基因組學整合進多模態電子健康紀錄基礎模型
28. JanusDNA：強大的雙向混合DNA基礎模型
29. 將基因組學整合至多模態電子健康紀錄基礎模型
30. JanusDNA：強大的雙向混合DNA基礎模型



生理訊號 / 醫療裝置-----

白鷗 x 喚
Daily Bio Juan

1. NeuroPilot：一種即時腦機介面系統以提升學生在線學習的專注力

摘要

在線學習的普及帶來了即時監控學生專注力的重要挑戰。傳統方法如問卷調查需要人工干預，而基於網絡攝像頭的監控因僅關注屏幕而未涉及認知參與，無法提供準確的學習者專注度信息。現有的腦機介面（BCI）方法缺乏即時驗證和評估程序。為了解決這些限制，開發了一種基於非侵入性腦電圖（EEG）頭帶FocusCalm的BCI系統，用於記錄專注和不專注狀態下的腦波活動。從20名參與者觀看預錄教育視頻中收集了20分鐘的數據。數據驗證採用了新穎的視頻內問卷評估。隨後，收集的信號經過分段（滑動窗口）、過濾（巴特沃斯帶通）和清理（去除高幅度和眼電圖（EOG）伪影如眨眼）。提取了時間、頻率、小波和統計特徵，然後使用支持向量機（SVM）進行遞歸特徵消除（RFE）以分類專注和不專注狀態。留一法交叉驗證（LOSO）的準確率為88.77%。系統在檢測到不專注狀態時提供反饋警報並維持專注狀態記錄。進行了一項試點研究以評估即時反饋的有效性。五名參與者進行了一個10分鐘的會話，包括5分鐘沒有反饋的基線階段，隨後是5分鐘的反饋階段，在此期間如果參與者表現出約8秒的注意力不集中則啟動警報。配對t檢驗（ $t = 5.73$, $p = 0.007$ ）顯示反饋階段專注力顯著提高。

導讀

這篇文章介紹了一種名為NeuroPilot的即時腦機介面（BCI）系統，旨在提升學生在在線學習中的專注力。傳統的專注力評估方法如問卷調查和網絡攝像頭監控存在不足，而這項研究使用非侵入性的腦電圖（EEG）頭帶FocusCalm來記錄專注和不專注狀態下的腦波活動。通過分析這些數據，系統可以區分專注和不專注狀態，並在檢測到不專注時發出警報。研究結果顯示，這種即時反饋可以顯著提高學生的專注力。

學習路徑

神經科學基礎 → 腦電圖（EEG）技術 → 腦機介面（BCI）系統 →
信號處理技術（如巴特沃斯濾波器） → 機器學習（支持向量機SVM） → 即時反饋系統設計

原文連結

點擊連結

2.

MoPFormer：用於可穿戴感測器活動識別的運動基元變壓器

摘要

使用可穿戴感測器進行人類活動識別（HAR）面臨著解釋性有限的挑戰，這對跨數據集的泛化能力有著顯著影響。為了解決這一挑戰，我們提出了運動基元變壓器（MoPFormer），這是一種新穎的自監督框架，通過將慣性測量單元信號轉換為語義上有意義的運動基元來增強可解釋性，並利用變壓器架構學習豐富的時間表徵。MoPFormer包括兩個階段。第一階段是將多通道感測器流劃分為短片段並量化為離散的「運動基元」代碼字，而第二階段則通過上下文感知嵌入模組豐富這些符號化序列，然後用變壓器編碼器處理它們。所提出的MoPFormer可以使用遮蔽運動建模目標進行預訓練，該目標重建缺失的基元，使其能夠在各種感測器配置中開發出穩健的表徵。在六個HAR基準上的實驗表明，MoPFormer不僅優於最先進的方法，還成功地在多個數據集上泛化。更重要的是，學習到的運動基元通過捕捉基本的運動模式，顯著增強了解釋性和跨數據集的性能，這些模式在類似活動中保持一致，無論數據集來源如何。

導讀

人類活動識別（HAR）是利用可穿戴感測器來了解和識別人類的各種活動。這項技術的挑戰在於如何解釋感測器數據，尤其是在不同的數據集之間進行泛化（即在不同的環境中保持準確性）。MoPFormer是一種新方法，它使用運動基元（基本的運動單位）來改善數據的解釋性。這個系統分為兩個階段：第一階段是將感測器數據分割並轉換為運動基元，第二階段則利用變壓器（Transformer，一種深度學習模型）來處理這些基元以學習時間序列的表徵。這樣的設計不僅提高了在不同數據集上的表現，還使得系統能夠捕捉到一致的運動模式。

學習路徑

可穿戴感測器技術 → 人類活動識別（HAR） → 自監督學習 → 運動基元 →
變壓器（Transformer）模型 → 時間序列分析 → 跨數據集泛化

原文連結

[點擊連結](#)

3. 高斯融合：基於高斯的多感測器融合技術，用於端到端自動駕駛

摘要

多感測器融合對於提升端到端自動駕駛系統的性能和穩健性至關重要。現有的方法主要採用基於注意力的平面融合或透過幾何轉換的鳥瞰圖融合。然而，這些方法往往存在解釋性有限或計算負擔過重的問題。本文介紹了一種基於高斯的多感測器融合框架，稱為GaussianFusion，用於端到端自動駕駛。我們的方法使用直觀且緊湊的高斯表示作為中介載體來聚合來自不同感測器的信息。具體而言，我們在駕駛場景中均勻地初始化一組二維高斯，每個高斯由物理屬性參數化，並配備顯性和隱性特徵。這些高斯通過整合多模態特徵進行逐步細化。顯性特徵捕捉交通場景的豐富語義和空間信息，而隱性特徵則提供對軌跡規劃有益的補充線索。為了充分利用高斯中的豐富空間和語義信息，我們設計了一個級聯規劃頭，通過與高斯的互動迭代地細化軌跡預測。在NAVSIM和Bench2Drive基準上的大量實驗證明了所提出的GaussianFusion框架的有效性和穩健性。源代碼將在<https://github.com/Say2L/GaussianFusion>發布。

導讀

多感測器融合是指將來自不同感測器的信息整合在一起，以提高系統的性能和穩定性。現有的方法通常使用注意力機制（用於選擇重要信息的技術）或鳥瞰圖（從上方觀察的視角）進行融合，但這些方法可能難以解釋或計算量大。本文提出了一種新的融合方法，稱為GaussianFusion，使用高斯分布（一種統計模型）來表示和整合信息。這種方法能夠有效捕捉交通場景中的重要信息，並通過級聯規劃頭（多層次的決策系統）來優化自動駕駛的軌跡規劃。

學習路徑

統計學基礎 → 機器學習 → 感測器技術 → 自動駕駛技術 → 多感測器融合 → 高斯分布應用 → GaussianFusion框架

原文連結

點擊連結

4. PULSE：從皮膚電活動到低成本感測器的壓力監測知識轉移

摘要

皮膚電活動 (Electrodermal Activity, EDA) 是壓力檢測的主要信號，但需要昂貴的硬體，通常在現實世界的穿戴裝置中無法獲得。在本文中，我們提出了PULSE，一個框架，該框架在自我監督的預訓練過程中僅使用EDA，同時在推斷階段不需要EDA，而是使用更容易獲得的模態，如心電圖 (ECG)、血容積脈搏 (BVP)、加速度計 (ACC) 和溫度 (TEMP)。我們的方法將編碼器輸出分為共享和私有嵌入。我們對齊跨模態的共享嵌入，並將它們融合成一個模態不變的表示。私有嵌入則攜帶模態特定的信息以支持重建目標。預訓練之後是知識轉移，其中凍結的EDA教師將交感神經喚起的表示轉移到學生編碼器。在WESAD數據集上，我們的方法實現了強大的壓力檢測性能，顯示出特權EDA的表示可以轉移到低成本感測器上，以提高準確性並降低硬體成本。

導讀

皮膚電活動 (EDA) 是用來檢測壓力的主要信號，但因為需要昂貴的設備，所以在一般的穿戴裝置上不常見。文章提出了一個名為PULSE的框架，這個框架在預訓練階段使用EDA，但在實際使用時則利用更常見的感測器（如心電圖ECG、血容積脈搏BVP、加速度計ACC和溫度TEMP）來進行壓力檢測。PULSE的方法是將數據分為共享和私有部分，並在不同的感測器間對齊共享部分，形成一個不依賴於特定感測器的表示。這樣的設計讓低成本的感測器也能有效地檢測壓力，降低了硬體成本。

學習路徑

生物感測技術 → 皮膚電活動 (EDA) → 自我監督學習 → 知識轉移 → 壓力檢測技術

原文連結

點擊連結

5. NeuroPilot：即時腦機介面系統提升學生在線學習專注力

摘要

隨著在線學習的普及，如何即時監控學生的專注力成為一大挑戰。傳統方法如問卷評估需要人工介入，而基於攝像頭的監控因僅能觀察屏幕注視而無法準確反映學習者的心智專注度。現有基於腦機介面（BCI）的方法缺乏即時驗證和評估程序。為了解決這些限制，研究人員開發了一種使用非侵入性腦電圖（EEG）頭帶FocusCalm的BCI系統，用以記錄學生在專注和不專注狀態下的腦波活動。研究中，20名參與者觀看預錄教育影片，每人收集20分鐘的數據。數據驗證使用新穎的影片內問卷評估。隨後，收集的信號經過分段（滑動窗口）、過濾（巴特沃斯帶通）和清理（去除高振幅和眼電圖偽影如眨眼）。提取了時間、頻率、小波和統計特徵，並使用支持向量機（SVM）的遞歸特徵消除（RFE）分類專注和不專注狀態。留一法交叉驗證（LOSO）的準確率為88.77%。系統在檢測到不專注狀態時提供反饋警報並維護專注度記錄。進行了一項試點研究以評估即時反饋的有效性。五名參與者進行了10分鐘的測試，包括5分鐘無反饋的基線階段，隨後是5分鐘的反饋階段，若參與者表現出約8秒的注意力不集中則啟動警報。配對t檢驗（ $t = 5.73$, $p = 0.007$ ）顯示反饋階段專注力顯著提高。

導讀

這篇文章介紹了一種名為NeuroPilot的腦機介面（BCI）系統，旨在提升學生在線學習時的專注力。該系統使用非侵入性的腦電圖（EEG）頭帶FocusCalm來監測學生的腦波活動，以區分專注和不專注狀態。研究中使用了支持向量機（SVM）進行數據分析，並在檢測到不專注時提供即時反饋。試點研究顯示，這種反饋能顯著提高學生的專注力。

學習路徑

腦電圖（EEG） → 腦機介面（BCI） → 機器學習（Machine Learning） → 支持向量機（SVM） → 即時數據分析（Real-time Data Analysis）

原文連結

點擊連結



神經科學 / 心理學-----

白鷗 x 喚
Daily Bio Juan

6. 物體綁定是否自然出現在大型預訓練視覺變壓器中？

摘要

物體綁定 (Object binding) 是大腦將代表一個物體的多個特徵綁定成一個連貫整體的能力，這對人類認知至關重要。它將低層次的感知特徵組合成高層次的物體表徵，並以高效且組合的方式在記憶中存儲這些物體，支持人類對單個物體實例的推理。雖然先前的研究通常顯式地施加以物體為中心的注意力 (例如，Slot Attention) 來探究這些好處，但尚不清楚這種能力是否自然出現在預訓練的視覺變壓器 (ViTs) 中。直觀上，這是可能的：識別哪些圖像區塊屬於同一個物體應該對下游預測有用，從而指導注意力。基於自注意力的二次性質，我們假設ViTs能夠表示兩個區塊是否屬於同一個物體，我們稱之為IsSameObject。我們使用相似性探測器從ViT層中的區塊嵌入中解碼IsSameObject，達到超過90%的準確率。關鍵是，這種物體綁定能力在自監督的ViTs (如DINO、MAE、CLIP) 中可靠地出現，但在ImageNet監督的模型中則明顯較弱，這表明綁定不是一個簡單的架構產物，而是通過特定預訓練目標獲得的能力。我們進一步發現，IsSameObject被編碼在物體特徵之上的低維子空間中，這種信號積極地指導注意力。從模型激活中消除IsSameObject會降低下游性能，並違背學習目標，這意味著自然出現的物體綁定自然地服務於預訓練目標。我們的發現挑戰了ViTs缺乏物體綁定的觀點，並強調了「哪些部分屬於一起」的符號知識如何自然地在連結主義系統中出現。

導讀

物體綁定是指大腦能夠將不同的感知特徵整合成一個完整的物體概念。這項研究探討了這種能力是否會在大型預訓練的視覺變壓器 (ViTs) 中自然出現。研究發現，自監督學習的ViTs能夠自然而然地學習到這種能力，並且這種能力對於模型的預測性能有重要影響。相較之下，使用ImageNet監督學習的模型則較少展現出這種能力，顯示出特定的預訓練目標在學習過程中的重要性。

學習路徑

感知科學 → 神經科學 → 機器學習 → 深度學習 → 視覺變壓器 (ViTs) → 自監督學習 → 物體綁定

原文連結

點擊連結

7. 多模態夢境：基於全球工作空間的世界模型強化學習方法

摘要

人類利用豐富的內部世界模型來推理未來、想像反事實並靈活適應新情況。在強化學習（Reinforcement Learning, RL）中，世界模型旨在捕捉環境如何隨著代理人行動而演變，從而促進規劃和泛化。然而，典型的世界模型直接作用於環境變量（如像素、物理屬性），這可能使其訓練緩慢而繁瑣；相反，依賴於捕捉相關多模態變量的高階潛在維度可能更為有利。全球工作空間（Global Workspace, GW）理論提供了一個認知框架，用於大腦中的多模態整合和信息廣播，最近的研究開始引入GW的高效深度學習實現。在此，我們評估了一個結合GW與世界模型的RL系統的能力。我們將我們的GW-Dreamer與標準PPO和原始Dreamer算法的各種版本進行比較。我們展示了在GW潛在空間內進行夢境過程（即，心智模擬）允許使用更少的環境步驟進行訓練。作為一個額外的湧現特性，結果模型（但不是其比較基線）對缺少其觀察模態之一（圖像或模擬屬性）表現出強大的魯棒性。我們得出結論，GW與世界模型的結合在改進RL代理的決策制定方面具有巨大潛力。

導讀

這篇文章探討了如何在強化學習中使用全球工作空間理論來改善世界模型。強化學習是一種讓電腦學習如何在不同環境中做出決策的方法。通常，這些模型直接處理環境中的數據（如圖片或物理屬性），但這樣會使得訓練過程變得很慢。全球工作空間理論是一種解釋大腦如何整合不同信息的理論，這篇文章利用該理論來改善強化學習模型的效率和魯棒性（即模型在面對不完整信息時仍能有效運作的能力）。

學習路徑

心理學 → 認知科學 → 全球工作空間理論 → 機器學習 → 深度學習 → 強化學習 → 世界模型 → 多模態學習

原文連結

點擊連結

8. NOBLE -- 神經運算符與生物信息潛在嵌入，用於捕捉生物神經元模型中的實驗變異性

摘要

理解神經元的細胞特性對於了解其在大腦中的功能至關重要。在這個過程中，生成生物真實性模型對於整合多模態細胞數據集和建立因果關係至關重要。然而，當前的建模方法受到實驗神經元數據的有限性和內在變異性的限制。生物真實性模型的確定性形式目前無法解釋實驗中觀察到的自然變異性。雖然深度學習在這一領域變得越來越重要，但它未能捕捉到神經元的全部生物物理複雜性、非線性電壓動態和變異性。為了解決這些不足，我們引入了NOBLE，一個神經運算符框架，學習從可解釋神經元特徵的連續頻率調製嵌入到由電流注入引起的體細胞電壓反應的映射。NOBLE在從生物真實性神經元模型生成的合成數據上進行訓練，預測考慮到內在實驗變異性的神經動態分佈。與傳統的生物真實性神經元模型不同，在嵌入空間內插提供的模型，其動態與實驗觀察到的反應一致。NOBLE能夠高效地生成與實驗數據非常相似且表現出試驗間變異性的合成神經元，提供了比數值求解器快4200倍的速度提升。NOBLE是第一個使用真實實驗數據驗證其泛化能力的擴展深度學習框架。為此，NOBLE以獨特且新興的方式捕捉了基本的神經特性，這為更好地理解細胞組成和計算、神經形態架構、大規模大腦電路和一般神經AI應用開啟了大門。

導讀

NOBLE是一個新的神經運算符框架，旨在解決當前神經元模型在處理實驗數據變異性方面的不足。傳統的生物真實性模型通常無法解釋實驗中觀察到的自然變異性，而NOBLE通過學習神經元特徵的嵌入來預測神經動態，從而提供更準確的模擬結果。這一框架不僅能夠生成與實驗數據相似的合成神經元，還能顯著提高計算速度。NOBLE的創新之處在於它能夠捕捉神經元的基本特性，這對於理解大腦的細胞組成和計算過程具有重要意義。

學習路徑

神經科學基礎 → 生物物理學 → 神經元模型 → 深度學習 → 神經運算符 → NOBLE框架

原文連結

[點擊連結](#)

9. 中風病灶分割在臨床工作流程中的應用：一個模組化、輕量化且可部署的工具

摘要

深度學習框架如 nnU-Net 在腦部病灶分割上達到了最先進的性能，但由於其繁重的依賴性和單一設計，使其在臨床上難以部署。我們介紹了一個名為 `StrokeSeg` 的模組化輕量框架，將研究級的中風病灶分割模型轉化為可部署的應用。預處理、推論和後處理被解耦：預處理依賴於 Anima 工具箱，並生成符合 BIDS 標準的輸出；推論使用 ONNX Runtime 並應用 `Float16` 量化，將模型大小減少約 50%。`StrokeSeg` 提供圖形和命令行界面，並以 Python 腳本和獨立的 Windows 可執行文件形式發佈。在一組 300 名亞急性和慢性中風受試者的數據集上，分割性能與原始的 PyTorch 管道相當（Dice 差異 $<10^{-3}$ ），證明高性能的研究管道可以轉化為便攜且臨床可用的工具。

導讀

這篇文章介紹了一種新的工具 `StrokeSeg`，用於中風病灶的分割。傳統的深度學習框架如 nnU-Net 雖然在分割腦部病灶方面表現優異，但由於其複雜性，難以在臨床環境中使用。`StrokeSeg` 則是一個模組化（可拆分成獨立部分）和輕量化（減少資源需求）的框架，能夠將研究級的模型轉化為實際可用的應用。這個工具將預處理、推論和後處理分開處理，並利用 Anima 工具箱和 ONNX Runtime 來提升效率和減少模型大小。最終，這個工具在測試中顯示出與原始模型相當的性能，證明其在臨床應用中的潛力。

學習路徑

深度學習基礎 → 醫學影像處理 → 腦部病灶分割技術 → nnU-Net 框架 → ONNX Runtime → `Float16` 量化技術 → Anima 工具箱 → BIDS 標準

原文連結

點擊連結

10. 無監督偵測中風後腦部異常

摘要

中風後的MRI不僅可以描繪局部病灶，還能揭示如萎縮和腦室擴大等次級結構變化。這些異常日益被視為康復和結果的影像生物標記，但監督分割方法對其捕捉能力有限。我們評估了一種名為REFLECT的基於流的生成模型，用於無監督偵測中風患者的局部和非病灶異常。使用ATLAS數據的雙專家中央切片註釋，通過異常圖的自由響應ROC分析在物體層面評估性能。兩個模型分別在無病灶的中風患者切片（ATLAS）和健康對照組（IXI）上進行訓練，以測試訓練數據的影響。在ATLAS測試對象中，IXI訓練的模型在病灶分割上取得較高的效果（Dice = 0.37 vs 0.27），並提高了對非病灶異常的敏感性（FROC = 0.62 vs 0.43）。在完全健康的解剖結構上進行訓練可改善正常變異性的建模，從而實現更廣泛和更可靠的結構異常檢測。

導讀

這篇文章探討了一種新方法來偵測中風後腦部的異常變化。中風後，患者的腦部可能會出現局部病灶（如受損區域）和非病灶異常（如腦萎縮）。傳統的監督學習方法在偵測這些變化時有其限制。研究人員使用了一種名為REFLECT的生成模型，這是一種無監督學習方法（不需要預先標註的數據），來分析MRI影像。研究發現，在完全健康的腦部數據上訓練模型，可以更有效地偵測異常，這對於未來的中風康復評估有重要意義。

學習路徑

MRI基礎知識 → 中風病理學 → 影像生物標記 → 監督學習與無監督學習 → 生成模型（Generative Models） → ROC分析 → 結構異常檢測

原文連結

點擊連結



AI / 數據分析-----

白鷗 x 喚
Daily Bio Juan

11. 基因型-表現型整合：透過機器學習和個人化基因調控網絡預測癌症轉移

摘要

癌症轉移是導致癌症相關死亡的主要原因，但大多數預測模型依賴於淺層架構，忽視了患者特異性的調控機制。在此研究中，我們整合了傳統機器學習和深度學習技術，以預測多種癌症類型的轉移潛力。我們使用了來自癌症細胞系百科全書（Cancer Cell Line Encyclopedia）的基因表達譜，並結合了來自DoRothEA的轉錄因子-靶標先驗知識，重點關注九種與轉移相關的調控因子。通過Kruskal-Wallis檢驗選擇差異基因後，訓練了ElasticNet、隨機森林（Random Forest）和XGBoost模型進行基準測試。接著，使用PANDA和LIONESS構建個人化基因調控網絡，並通過圖注意力神經網絡（GATv2）分析，以學習基於拓撲和表達的表示。儘管XGBoost達到了最高的AUROC（0.7051），但GNN在患者層面捕捉到了非線性調控依賴性。這些結果表明，將傳統機器學習與基於圖的深度學習結合，能夠提供一個可擴展且可解釋的框架，用於精準腫瘤學中的轉移風險預測。

導讀

癌症轉移是癌症死亡的主要原因，但目前的預測模型往往忽略了患者個體的差異性。這項研究結合了傳統機器學習（如ElasticNet、隨機森林和XGBoost）和深度學習技術（如圖神經網絡GNN），來提高對癌症轉移的預測準確性。研究使用了癌症細胞系百科全書的基因數據，並重點分析了九種關鍵的轉移調控因子。研究發現，XGBoost模型在預測準確性上表現最佳，但GNN能夠更好地捕捉患者層面的非線性調控關係，這為精準腫瘤學提供了一個新的預測框架。

學習路徑

基因表達 → 機器學習基礎 → 深度學習基礎 → 癌症生物學 → 基因調控網絡 → 圖神經網絡（GNN） → 精準醫療

原文連結

點擊連結

12. 腸道決策基於肝臟：利用放射組學提升大腸癌篩檢

摘要

非侵入性的大腸癌（CRC）篩檢是提高結腸鏡檢查參與率和降低大腸癌死亡率的關鍵機會。本研究探討了通過從常規CT影像中提取的肝臟衍生放射組學特徵，來預測大腸腫瘤的腸肝軸潛力，作為一種新穎的機會性篩檢方法。在這項回顧性研究中，我們分析了1,997名接受結腸鏡檢查和腹部CT的患者數據。患者要麼沒有大腸腫瘤（ $n=1,189$ ），要麼有大腸腫瘤（總數 $n=808$ ；腺瘤 $n=423$ ，大腸癌 $n=385$ ）。使用放射組學處理工具包（RPTK）從3D肝臟分割中提取放射組學特徵，進行特徵提取、過濾和分類。數據集分為訓練組（ $n=1,397$ ）和測試組（ $n=600$ ）。五個機器學習模型在20個最具信息量的特徵上進行5折交叉驗證訓練，並根據驗證AUROC選擇最佳模型集成。基於放射組學的XGBoost模型在測試中的AUROC達到0.810，明顯優於僅臨床模型（測試AUROC：0.457）。在大腸癌和腺瘤之間的亞分類顯示出較低的準確性（測試AUROC：0.674）。我們的研究結果證明了從常規腹部CT中提取的肝臟衍生放射組學可以預測大腸腫瘤。除了提供一種實用、廣泛可及的CRC篩檢輔助手段外，這一方法還強調了腸肝軸作為機會性篩檢的新型生物標誌物來源，並激發了未來轉化研究的新機制假說。

導讀

這篇文章探討了一種利用肝臟的放射組學特徵來提升大腸癌篩檢的方法。放射組學（Radiomics）是一種從醫學影像中提取大量特徵的技術，這些特徵可以用來預測疾病。研究人員使用了來自常規CT影像的肝臟數據，並通過機器學習模型來預測大腸腫瘤的存在。這種方法不僅可以作為現有篩檢手段的輔助手段，還為未來的研究提供了新的方向。

學習路徑

醫學影像學 → 放射組學 → 機器學習 → 大腸癌篩檢 → 生物標誌物研究

原文連結

點擊連結

13. 機器學習方法在抗體屬性預測中的應用：結構數據的解釋性

摘要

理解抗體序列、結構與功能之間的關係對於設計基於抗體的治療和研究工具至關重要。近期，主要基於大型語言模型應用於序列信息的機器學習（ML）模型已被開發用於預測抗體特性。然而，如何結合結構信息來增強預測並提供分子機制的見解仍是開放的研究方向。本章概述了這些方法，並描述了兩個整合結構數據（通過圖形表示）與神經網絡的機器學習框架：ANTIPASTI預測結合親和力（一種全局特性），而INFUSSE預測殘基柔性（一種局部特性）。我們調查了這些模型的基本原理；它們編碼結構知識的方式；以及可用於提取生物學相關統計信號的策略，這些信號有助於發現和解開感興趣特性的分子決定因素。

導讀

這篇文章探討了如何利用機器學習模型來預測抗體的屬性。抗體是免疫系統的重要組成部分，其序列和結構決定了它們的功能。傳統上，預測抗體屬性主要依賴於序列信息，但這篇文章提出了結合結構信息的方法。ANTIPASTI和INFUSSE是兩個利用結構數據的模型，分別用於預測抗體的結合親和力（抗體與抗原結合的強度）和殘基柔性（抗體中特定氨基酸的靈活性）。這些模型通過圖形表示和神經網絡來分析抗體的結構，提供了更深入的生物學見解。

學習路徑

生物化學基礎 → 抗體結構與功能 → 機器學習基礎 → 神經網絡 → 大型語言模型 → 結構生物學 → 圖形表示技術 → 抗體屬性預測模型

原文連結

點擊連結

14. 精準醫療中的N-of-1人工智慧生態系統

摘要

醫學中的人工智慧通常是為了服務「平均病人」而設計的。透過在大型數據集上最小化錯誤，大多數系統能夠提供強大的整體準確性，但在邊緣情況下卻容易失敗，例如具有罕見變異、多重病症或代表性不足的人群。這種「平均病人謬誤」削弱了公平性和信任。我們提出了一種不同的設計：一個針對N-of-1決策支持的多代理生態系統。在這個環境中，依據器官系統、患者群體和分析模式聚集的代理，利用共享的模型庫和證據綜合工具。它們的結果在一個協調層中匯聚，該層在向臨床醫生提供決策支持包之前，會權衡可靠性、不確定性和數據密度：包括置信範圍內的風險估計、異常值標記和鏈接證據。驗證從人口平均轉向個體可靠性，通過低密度區域的錯誤、小樣本校準和風險-覆蓋權衡來測量。預期的挑戰包括計算需求、自動化偏見和法規適配，這些問題將通過緩存策略、共識檢查和自適應試驗框架來解決。從單一模型轉向協調智能，這種方法旨在使醫療人工智慧與醫學的第一原則保持一致：透明、公平且以個體為中心的照護。

導讀

這篇文章探討了一種新的人工智慧系統設計，稱為「N-of-1人工智慧生態系統」，旨在改善精準醫療（Precision Medicine）。傳統上，醫學人工智慧系統是為了服務「平均病人」，但這種方法可能忽略了罕見病症或多重病症患者的需求。N-of-1系統則是透過多個代理（Agents）來支持個別患者的決策，這些代理會根據不同的器官系統和患者群體來運作，並使用共享的模型和工具來分析數據。這樣的系統不僅能提供個體化的醫療建議，還能提高醫療的透明度和公平性。

學習路徑

醫學人工智慧基礎 → 精準醫療 → 多代理系統 → N-of-1方法 → 個體化醫療決策支持

原文連結

點擊連結

15. Pearl：一個將每個原子放置在正確位置的基礎模型

摘要

準確預測蛋白質-配體複合物的三維結構仍然是計算藥物發現中的一項基本挑戰，限制了治療設計的速度和成功率。深度學習方法最近顯示出作為結構預測工具的強大潛力，在各種生物分子系統中取得了令人鼓舞的準確性。然而，它們的性能和實用性受到實驗數據稀缺、架構效率低下、物理上無效的構型以及在推理時利用輔助信息的能力有限的限制。為了解決這些問題，我們引入了Pearl (Placing Every Atom in the Right Location)，這是一個用於大規模蛋白質-配體共摺疊的基礎模型。Pearl通過三個關鍵創新解決這些挑戰：(1) 包括大規模合成數據的訓練方案，以克服數據稀缺；(2) 包含SO(3)等變擴散模塊的架構，從而內在地尊重三維旋轉對稱性，提高泛化和樣本效率；(3) 可控推理，包括支持蛋白質和非聚合物組件的廣義多鏈模板系統，以及雙無條件/條件模式。Pearl在蛋白質-配體共摺疊中建立了新的最先進性能。在生成準確 ($\text{RMSD} < 2 \text{ \AA}$) 且物理上有效的構型的關鍵指標上，Pearl超過了AlphaFold 3和其他開源基準，在公共的RMS N' Poses和PoseBusters基準上分別提供了14.5%和14.2%的改進。在口袋條件共摺疊模式中，Pearl在更嚴格的 $\text{RMSD} < 1 \text{ \AA}$ 閾值下對一組具有挑戰性的真實世界藥物靶標提供了3.6倍的改進。最後，我們證明模型性能與訓練中使用的合成數據集大小直接相關。

導讀

在計算藥物發現中，準確預測蛋白質和配體（小分子）如何結合是非常重要的。這篇文章介紹了一個名為Pearl的模型，它能夠更準確地預測這些結合結構。Pearl使用了大量的合成數據來訓練，並採用了能夠尊重三維旋轉對稱性的架構，這使得它能夠更好地泛化（即在不同情境下仍能有效工作）。此外，Pearl還能在推理時靈活地使用不同的模式，這使得它在多種基準測試中表現優於現有的模型，如AlphaFold

3。這些改進對於開發新藥物具有重要意義，因為它們能夠更快、更準確地找到潛在的藥物靶標。

學習路徑

生物化學 → 結構生物學 → 計算生物學 → 深度學習 → 蛋白質-配體對接 → 基礎模型 (Foundation Models)

原文連結

點擊連結



產業趨勢 / 法規-----

白鷗 x 喚
Daily Bio Juan

16. CFM-GP：統一條件流匹配以學習跨細胞類型的基因擾動

摘要

理解基因擾動在不同細胞環境中的影響是功能基因組學的一個核心挑戰，這對於治療發現和精準醫療具有重要意義。單細胞技術可以高解析度地測量轉錄反應，但收集這些數據既昂貴又耗時，特別是當需要對每一種細胞類型重複測量時。現有的計算方法通常需要為每種細胞類型建立獨立模型，限制了其可擴展性和泛化能力。我們提出了一種名為CFM-GP的方法，用於細胞類型無關的基因擾動預測。CFM-GP學習在未擾動和擾動基因表達分佈之間的連續、時間依賴轉換，並以細胞類型為條件，允許單一模型預測所有細胞類型。與先前使用離散建模的方法不同，CFM-GP採用流匹配目標，以可擴展的方式捕捉擾動動態。我們在五個數據集上進行了評估：SARS-CoV-2感染、IFN-beta刺激的PBMCs、用Panobino stat處理的膠質母細胞瘤、IFN-beta刺激下的狼瘡，以及Statefate progenitor命運映射。CFM-GP在R平方和Spearman相關性上始終優於最新的基線，且途徑富集分析證實了關鍵生物途徑的恢復。這些結果證明了CFM-GP作為跨細胞類型基因擾動預測的可擴展解決方案的穩健性和生物學真實性。

導讀

這篇文章介紹了一種新的方法CFM-GP，用於預測基因在不同細胞類型中的擾動效果。基因擾動（基因表達的改變）對理解疾病和開發治療方法非常重要。傳統方法需要為每種細胞類型建立單獨的模型，而CFM-GP可以在不區分細胞類型的情況下進行預測，這樣可以節省時間和成本。CFM-GP使用了一種叫做「流匹配」（flow matching）的技術來捕捉基因擾動的動態過程，這使得它在多個數據集上的表現超過了現有的方法。

學習路徑

基因組學 → 單細胞技術 → 基因擾動 → 計算生物學 → 機器學習 → 流匹配技術

原文連結

點擊連結

17. 因果感知生成對抗網絡與強化學習

摘要

表格式數據在從模型訓練到大規模數據分析的任務中，常因隱私問題或法規障礙而受到限制。雖然現有的數據生成方法，特別是基於生成對抗網絡（GANs）的方法，顯示出潛力，但它們經常難以捕捉複雜的因果關係，維持數據效用，並提供適合企業部署的可證明隱私保證。我們引入CA-GAN，一種專門設計用於解決現實世界表格式數據集挑戰的新生成框架。CA-GAN採用兩步驟方法：首先，因果圖提取以學習數據流形中的穩健、全面的因果關係；接著，使用一種自定義的條件WGAN-GP（帶梯度懲罰的Wasserstein GAN），該方法僅按因果圖中的節點結構運行。更重要的是，生成器通過一種基於強化學習的新目標進行訓練，使從真實和虛假數據構建的因果圖對齊，確保在訓練和取樣階段的因果感知。我們在14個表格式數據集上展示了CA-GAN相較於六種SOTA方法的優越性。我們的評估重點在於核心數據工程指標：因果保留、效用保留和隱私保留。我們的方法為數據工程師提供了一種實用的高性能解決方案，用於創建高質量、符合隱私的合成數據集，以基準測試數據庫系統，加速軟件開發，並促進安全的數據驅動研究。

導讀

這篇文章介紹了一種新型的生成對抗網絡（GAN）框架，稱為CA-GAN，專門用於解決表格式數據的隱私和因果關係問題。表格式數據是指以行和列的形式組織的數據，常見於電子表格和數據庫中。CA-GAN使用因果圖（描述變量之間因果關係的圖形結構）來捕捉數據中的因果關係，並利用條件WGAN-GP（Wasserstein GAN的一種變體）來生成數據。該方法還引入了強化學習（Reinforcement Learning，一種機器學習方法，通過獎勵和懲罰來訓練模型）來確保生成的數據與真實數據具有相似的因果結構。這樣的技術可以幫助數據工程師創建高質量的合成數據，這些數據在隱私和數據效用上都能滿足企業需求。

學習路徑

數據隱私 → 生成對抗網絡（GANs） → 因果圖 → Wasserstein GAN → 強化學習 → 合成數據生成 → 數據工程

原文連結

點擊連結

18. CFM-GP：統一條件流匹配學習跨細胞類型基因擾動

摘要

理解基因擾動在不同細胞環境中的影響是功能基因組學中的核心挑戰，對於治療發現和精準醫療有重要意義。單細胞技術可以高解析度地測量轉錄反應，但收集這些數據既昂貴又耗時，尤其是當需要對每種細胞類型重複測量時。現有的計算方法通常需要為每種細胞類型建立單獨的模型，限制了其可擴展性和普適性。我們提出了CFM-GP，一種不依賴於細胞類型的基因擾動預測方法。CFM-GP學習未擾動和擾動基因表達分佈之間的連續、時間依賴的轉換，並以細胞類型為條件，允許單一模型預測所有細胞類型。與先前使用離散建模的方法不同，CFM-GP採用了流匹配目標，以可擴展的方式捕捉擾動動態。我們在五個數據集上進行評估：SARS-CoV-2感染、IFN-beta刺激的PBMCs、用Panobinostat治療的膠質母細胞瘤、IFN-beta刺激下的紅斑狼瘡，以及Statefate progenitor命運映射。CFM-GP在R平方和Spearman相關性上持續優於最先進的基準，且通路富集分析證實了關鍵生物通路的恢復。這些結果展示了CFM-GP作為跨細胞類型基因擾動預測的可擴展解決方案的穩健性和生物學真實性。

導讀

CFM-GP是一種新穎的方法，用於預測不同細胞類型中基因擾動的影響。基因擾動（Gene Perturbation）指的是基因表達受到改變的過程。傳統方法需要為每種細胞類型建立單獨的模型，這樣做不僅耗時且不易擴展。CFM-GP通過學習基因表達在未擾動和擾動狀態下的轉變，並以細胞類型為條件，實現了一個模型適用於所有細胞類型。這種方法使用流匹配（Flow Matching）來捕捉擾動的動態變化，並在多個數據集上表現出色，顯示出其在預測基因擾動方面的潛力。

學習路徑

基因組學 → 單細胞技術 → 基因擾動 → 計算生物學 → 流匹配技術 → CFM-GP模型

原文連結

點擊連結

19. CMS批准腎臟去神經術的全國覆蓋，惠及美敦力和Recor

摘要

全國醫療保險覆蓋為更多患者群體提供了獲得血壓治療的途徑，該治療已於2023年獲得FDA批准。這項覆蓋政策的實施將有助於腎臟去神經術（renal denervation）的推廣，這是一種用於治療高血壓的創新技術。美敦力（Medtronic）和Recor兩家公司將從中受益，因為它們是該技術的主要供應商。

導讀

腎臟去神經術是一種針對高血壓的治療方法，通過使用射頻能量來破壞腎動脈周圍的交感神經（負責調節血壓的神經系統）。這項技術的目的是降低血壓，特別是對於那些對傳統藥物治療無效的患者。美敦力和Recor是這一領域的領先公司，現在隨著全國醫療保險的覆蓋，更多患者將能夠接受這種治療。

學習路徑

高血壓 → 血壓調節機制 → 交感神經系統 → 腎臟去神經術 → 射頻能量應用 → 醫療保險政策

原文連結

[點擊連結](#)

白鷗 x 喚
Daily Bio Juan

20. 羅氏承諾向中國生技公司投資10億美元，用於開發臨床前階段的雙特異性抗體治療COPD

摘要

羅氏（Roche）正與位於中國江蘇的Qyuns Therapeutics合作，開發一種雙特異性抗體，該抗體有潛力治療哮喘、慢性阻塞性肺病（COPD）及其他呼吸系統疾病。為了啟動與Qyuns的合作，羅氏將首先支付7,000萬美元的預付款。

導讀

羅氏是一家全球知名的製藥公司，正在與中國的Qyuns Therapeutics合作。雙特異性抗體是一種能同時結合兩種不同抗原的抗體，這意味著它可以同時針對多種疾病機制。這項合作的目的是開發一種新的治療方法，主要針對哮喘和COPD等呼吸系統疾病。COPD是一種常見的慢性肺部疾病，會導致呼吸困難，通常由長期吸煙或空氣污染引起。

學習路徑

生物學基礎 → 免疫學 → 抗體結構與功能 → 雙特異性抗體 → 呼吸系統疾病（如哮喘、COPD） → 生物製藥合作模式

原文連結

點擊連結

白鷗 x 喚
Daily Bio-Fun



生科基礎研究-----

白鷗 x 喚
Daily Bio Juan

21. PanDelos-plus：在泛基因組分析中計算序列同源性的平行算法

摘要

在細菌泛基因組學中，識別多個基因組間的同源基因家族是一項核心任務，傳統上需要計算量大的全對全比較。PanDelos通過基於k-mer（固定長度的DNA片段）特徵的無比對、無參數方法應對這一挑戰，結合了高速度、易用性和與最新方法相媲美的準確性。然而，隨著基因組數據的日益增多，需要能夠有效擴展到更大數據集的工具。為了解決這一需求，我們推出了PanDelos-plus，一個完全平行的、基於基因的PanDelos重新設計。該算法通過數據分解和線程池策略平行化了最耗計算資源的階段（最佳命中檢測和雙向最佳命中提取），同時使用輕量級數據結構來減少內存使用。在合成數據集上的基準測試顯示，PanDelos-plus的執行速度提高了最多14倍，內存使用減少了最多96%，同時保持準確性。這些改進使得在標準多核工作站上進行群體規模的比較基因組學成為可能，讓大規模細菌泛基因組分析在日常研究中變得可行。

導讀

泛基因組學（研究一組生物的全部基因組）中，識別基因組間的同源性（基因或蛋白質的相似性）是重要的，但傳統方法計算量大。PanDelos利用k-mer特徵（固定長度的DNA片段）來快速識別同源性，而PanDelos-plus則進一步提升了效率。它通過平行化（同時進行多個計算過程）和輕量級數據結構（減少內存使用的數據組織方式）來加速處理，使得在普通的多核電腦上也能進行大規模的基因組分析。

學習路徑

基因組學 → 同源性分析 → k-mer特徵 → 泛基因組學 → 平行計算 → PanDelos算法 → PanDelos-plus算法

原文連結

點擊連結

22. 將基因組學整合進多模態電子健康紀錄基礎模型

摘要

本文介紹了一種創新的電子健康紀錄（EHR）基礎模型，將多基因風險評分（Polygenic Risk Scores, PRS）作為基礎數據模態進行整合，超越傳統僅依賴EHR的方法，建立更全面的健康檔案。利用來自「All of Us」（AoU）研究計畫的大量多樣數據，這一多模態框架旨在學習臨床數據與基因傾向之間的複雜關係。該方法將生成式人工智慧的進展延伸至EHR基礎模型領域，增強了預測能力和可解釋性。基於AoU數據的評估顯示，該模型在預測各種疾病（尤其是第二型糖尿病）發病方面具有預測價值，並展示了PRS與EHR數據之間的相互作用。研究還探索了轉移學習在自定義分類任務中的應用，展示了該架構的多樣性和效率。這一方法對於揭示疾病預測、新的健康管理、風險分層和個性化治療策略的新見解至關重要，為更個性化、公平且可行的實證生成奠定了基礎。

導讀

這篇文章介紹了一種新的電子健康紀錄模型，將多基因風險評分（PRS）與傳統的健康數據結合，創造出更完整的健康檔案。利用「All of Us」研究計畫的數據，這個模型能夠學習臨床數據和基因之間的複雜關係。它運用了生成式人工智慧（Generative AI）的技術來增強預測能力，特別是在預測第二型糖尿病方面。這種方法不僅能預測疾病，還能幫助制定個性化的健康管理和治療策略。

學習路徑

基因組學 → 多基因風險評分（PRS） → 電子健康紀錄（EHR） → 生成式人工智慧（Generative AI） → 多模態數據整合 → 轉移學習

原文連結

點擊連結

23. JanusDNA：強大的雙向混合DNA基礎模型

摘要

大型語言模型（LLMs）已經在自然語言處理領域引發革命，並逐漸應用於其他序列數據類型，包括基因序列。然而，將LLMs應用於基因組學面臨重大挑戰。捕捉複雜的基因組交互需要對DNA序列中的長距依賴性進行建模，這些交互通常跨越超過10,000個鹼基對，即使在單一基因內，這也對傳統模型架構和訓練範式構成了巨大的計算負擔。此外，標準的LLM訓練方法對DNA來說並不理想：自回歸訓練雖然高效，但僅支持單向理解。然而，DNA本質上是雙向的，例如，雙向啟動子在兩個方向上調節轉錄，約佔人類基因表達的11%。掩蔽語言模型（MLMs）允許雙向理解，但效率低下，因為每步只有掩蔽的標記對損失有貢獻。為了解決這些限制，我們引入了JanusDNA，這是首個基於新預訓練範式的雙向DNA基礎模型，該範式結合了自回歸建模的優化效率和掩蔽建模的雙向理解。JanusDNA採用混合Mamba、Attention和專家混合（MoE）架構，結合了Attention的長距建模和Mamba的高效序列學習。MoE層通過稀疏激活進一步擴展模型容量，同時保持計算成本低。值得注意的是，JanusDNA在單個80GB GPU上以單核核苷酸分辨率處理多達100萬個鹼基對。廣泛的實驗和消融研究顯示，JanusDNA在三個基因組表示基準上達到了新的SOTA結果，超越了具有250倍更多激活參數的模型。

導讀

JanusDNA是一種新的基因組學模型，旨在解決將大型語言模型應用於DNA序列時遇到的挑戰。傳統模型難以處理DNA序列中的長距交互，因為這些交互可能跨越數千個鹼基對。JanusDNA通過結合自回歸（自我預測）和掩蔽語言模型（隱藏部分信息以進行預測）的優勢，實現了雙向理解。這意味著它可以更有效地理解DNA序列的雙向特性，如雙向啟動子在基因表達中的作用。JanusDNA還使用了一種名為專家混合（MoE）的技術，這使得模型可以在不增加計算成本的情況下擴展其容量。

學習路徑

基因組學入門 → 大型語言模型（LLMs） → 自回歸模型 → 掩蔽語言模型（MLMs） → 雙向DNA序列理解 → 專家混合（MoE）架構 → JanusDNA模型

原文連結

[點擊連結](#)

24. 將基因組學整合至多模態電子健康紀錄基礎模型

摘要

這篇論文介紹了一種創新的電子健康紀錄（EHR）基礎模型，將多基因風險評分（Polygenic Risk Scores, PRS）作為基礎數據模態，超越了傳統僅依賴EHR的方法，以構建更全面的健康概況。該多模態框架利用來自「我們所有人」（All of Us, AoU）研究計畫的廣泛且多樣化數據，旨在學習臨床數據與基因傾向之間的複雜關係。此方法將生成式人工智慧的進展延伸至EHR基礎模型領域，增強了預測能力和可解釋性。在AoU數據上的評估顯示，該模型對於各種疾病發作，特別是第二型糖尿病（Type 2 Diabetes, T2D）的預測價值，並展示了PRS與EHR數據之間的相互作用。該研究還探索了遷移學習在自訂分類任務中的應用，展示了該架構的多功能性和效率。這一方法對於揭示疾病預測、新的健康管理策略、風險分層和個性化治療策略具有關鍵意義，為在醫療保健中產生更個性化、公平且可操作的實證奠定了基礎。

導讀

這篇文章討論了一種新的方法，將多基因風險評分（PRS，一種基於基因數據的風險評估工具）與電子健康紀錄（EHR，一種數位化的病人健康信息系統）結合。這樣的結合能夠提供更全面的健康分析，特別是在預測疾病如第二型糖尿病（T2D）方面。研究利用了「我們所有人」研究計畫的數據，這是一個大型的健康數據庫，幫助模型學習臨床數據和基因之間的關聯。此外，文章還探討了遷移學習（一種機器學習技術，允許模型在不同但相關的問題上進行應用）在這一領域的應用，展示了這種方法的靈活性和有效性。

學習路徑

基因學 → 電子健康紀錄（EHR） → 多基因風險評分（PRS） → 生成式人工智慧 → 遷移學習 → 第二型糖尿病預測 → 個性化醫療

原文連結

點擊連結

25. JanusDNA：強大的雙向混合DNA基礎模型

摘要

大型語言模型（LLMs）已經徹底改變了自然語言處理，並逐漸應用於其他序列數據類型，包括基因序列。然而，將LLMs應用於基因組學面臨重大挑戰。捕捉複雜的基因組相互作用需要對DNA序列中的長距依賴性進行建模，這些相互作用通常跨越超過10,000個鹼基對，即使在單個基因內，也會給傳統模型架構和訓練範式帶來巨大的計算負擔。此外，標準的LLM訓練方法對DNA來說並不理想：自回歸訓練雖然高效，但僅支持單向理解。然而，DNA本質上是雙向的，例如，雙向啟動子在兩個方向上調控轉錄，佔人類基因表達的近11%。掩碼語言模型（MLMs）允許雙向理解，但效率低下，因為每步僅有掩碼標記對損失有貢獻。為了解決這些限制，我們引入了JanusDNA，這是第一個基於新預訓練範式的雙向DNA基礎模型，該範式結合了自回歸建模的優化效率和掩碼建模的雙向理解。JanusDNA採用了混合的Mamba、Attention和專家混合（MoE）架構，將Attention的長距建模與Mamba的高效序列學習相結合。MoE層通過稀疏激活進一步擴展模型容量，同時保持計算成本低。值得注意的是，JanusDNA在單個80GB GPU上以單核苷酸分辨率處理多達100萬個鹼基對。廣泛的實驗和消融研究顯示，JanusDNA在三個基因組表示基準上達到了新的SOTA結果，超越了激活參數多250倍的模型。

導讀

JanusDNA是一種新型的DNA基礎模型，旨在解決將大型語言模型應用於基因組學時遇到的挑戰。傳統的LLM方法在處理DNA序列時效率不高，因為DNA具有雙向性（可以在兩個方向上進行基因表達調控）。JanusDNA通過結合自回歸建模（預測下一個元素的過程）和掩碼建模（隱藏部分數據以訓練模型理解上下文）的優勢，實現了高效的雙向理解。該模型採用了Mamba、Attention和專家混合（MoE）技術，能夠在低計算成本下處理大量數據，並在基因組學的多項基準測試中表現出色。

學習路徑

基因組學 → 大型語言模型（LLMs） → 自回歸建模 → 掩碼語言模型（MLMs） → 雙向DNA模型 → JanusDNA架構（Mamba、Attention、MoE）

原文連結

點擊連結