

每日生醫新聞報告

技術導讀與學習地圖



產出日期：2025/11/26

目錄

1. 生理訊號 / 醫療裝置-----
2. 液壓大腦：全身共振中的約束釋放相變理解
3. 大腦-MGF：多模態圖融合網絡用於裸蓋菇素下的腦連接分析
4. 多目標擴散框架：提升腦解碼的普適性
5. 感知圖：從腦電圖重建視覺感知與推測電極偏好
6. 使用人工智慧技術對尖峰信號數據進行功能分類：綜述
7. 神經科學 / 心理學-----
8. 檢測阿茲海默症基因共表現拓撲的不連續性
9. 解碼抗氧化和抗炎營養補充品在中風中的科學
10. 一個普遍的相圖模型用於體內蛋白質聚集
11. 強健的核心-邊緣約束變壓器於領域適應
12. 深度學習在血腦屏障通透性預測中的應用
13. AI / 數據分析-----
14. 一個生態學知識驅動的深度學習框架，用於可解釋和可驗證的棲地映射
15. EscalNet：基於有效能量學習生物分子動力學的各向同性表示空間
16. 學習 T 細胞抗原識別原理
17. 人工智慧驅動的MALDI-TOF MS生成技術於微生物特徵分析
18. 基於數據驅動的微流控癌細胞分離預測模型在確定性橫向位移裝置中的應用
19. 微生物 / 微生態-----
20. 快速且靈活的通用圖流分解方法透過支配者
21. 產業趨勢 / 法規-----
22. 基因調控網絡中的穩定化原則：從離散動態系統的視角
23. 知識引導蒸餾：無需先驗的基因調控網路推斷
24. CFM-GP：統一條件流匹配以學習跨細胞類型的基因擾動
25. 標題
26. 生科基礎研究-----
27. 雙路徑知識增強對比對齊網絡用於空間解析轉錄組學
28. 大型化學反應網絡中自催化子系統的枚舉
29. 輔助基因學習：透過輔助基因選擇進行空間基因表達估計
30. 邁向開放式視覺科學發現：稀疏自編碼器的應用
31. 重新檢視多模態生存分析：從最小-最大觀點出發



生理訊號 / 醫療裝置-----

白鷗 x 喚
Daily Bio Juan

1. 液壓大腦：全身共振中的約束釋放相變理解

摘要

目前的模型將生理信號視為干擾神經計算的噪音。之前的研究顯示，去除這些「偽影」會消除70%的預測相關性，這意味著身體信號在功能上驅動認知。在這項研究中，我們使用高密度腦電圖（64個通道，10名受試者，超過500次試驗）研究P300目標識別過程中的機制。相位斜率指數（Phase Slope Index）顯示零時滯同步（PSI=0.000044， $p=0.061$ ）並具有高一致性（0.316， $p<0.0001$ ）。嶺正則化的Granger因果關係顯示出大規模的雙向耦合（腦到身體 $F=100.53$ ，身體到腦 $F=62.76$ ），在78.1毫秒時同時達到峰值，這與相互耦合的共振對一致。時間解析的熵分析（200毫秒窗口，25毫秒步長）顯示三相動態：（1）約束積累（0-78毫秒），在沒有熵變化的情況下建立因果驅動（ $\Delta S=-0.002$ bits， $p=0.75$ ）；（2）超臨界轉變（100-600毫秒），觸發狀態擴展（方向性增加58%，二項式 $p=0.002$ ）；（3）持續的亞穩態。關鍵是，轉變幅度與共振強度無關（ $r=-0.044$ ， $p=0.327$ ），表明二元閾值動態。理解通過一個熱力學序列出現：腦-身體共振作為觸發非線性信息整合的離散閘門。這種架構可能從根本上區分生物智能和人工智能。

導讀

這篇文章探討了身體信號如何影響大腦認知，挑戰了傳統上將生理信號視為噪音的觀點。研究使用高密度腦電圖（EEG，一種測量大腦電活動的技術）來分析P300目標識別過程，發現大腦和身體之間存在雙向的共振（resonance，一種同步振動現象）。這種共振可能扮演著觸發非線性信息整合的角色，並且這種過程可能是生物智能和人工智能的根本區別。

學習路徑

生理學基礎 → 神經科學 → 腦電圖技術 → 信號處理 → Granger因果關係 → 熵和信息理論 → 相變和熱力學 → 體現認知（embodied cognition） → 神經形態計算（neuromorphic computing）

原文連結

點擊連結

2. 大腦-MGF：多模態圖融合網絡用於裸蓋菇素下的腦連接分析

摘要

迷幻藥，如裸蓋菇素，能夠重組大腦的大規模連接，但這些變化如何反映在電生理（腦電圖，EEG）和血流動力學（功能性磁共振成像，fMRI）網絡中仍不清楚。我們提出了一種名為大腦-MGF的多模態圖融合網絡，用於聯合EEG-fMRI連接分析。對於每種模態，我們構建了具有部分相關邊和皮爾遜特徵節點的圖，並通過圖卷積學習個體級嵌入。自適應softmax門會融合具有樣本特定權重的模態，以捕捉上下文依賴的貢獻。利用全球最大的單一站點裸蓋菇素數據集PsiConnect，大腦-MGF能夠在冥想和靜息狀態下區分裸蓋菇素和非裸蓋菇素條件。融合比單模態和非自適應變體更優，冥想狀態下達到74.0%的準確率和76.5%的F1分數，靜息狀態下達到76.0%的準確率和85.8%的ROC-AUC。UMAP可視化顯示融合嵌入的類別分離更為清晰。這些結果表明，自適應圖融合有效整合了EEG-fMRI的互補信息，提供了一個可解釋的框架來表徵裸蓋菇素引起的大規模神經組織變化。

導讀

這篇文章介紹了一種新的方法——大腦-MGF，用於分析裸蓋菇素（迷幻藥的一種）對大腦連接的影響。研究者利用腦電圖（EEG）和功能性磁共振成像（fMRI）這兩種技術，通過圖卷積（graph convolution）來學習大腦的連接模式。自適應softmax門（adaptive softmax gate）則用來融合這兩種技術的數據，從而提高分析的準確性和可靠性。研究使用了PsiConnect數據集，顯示這種方法能更好地區分裸蓋菇素影響下的冥想和靜息狀態。

學習路徑

神經科學基礎 → 腦電圖（EEG） → 功能性磁共振成像（fMRI） → 迷幻藥與大腦連接 → 圖卷積網絡（Graph Convolutional Networks） → 多模態數據融合（Multimodal Data Fusion）

原文連結

點擊連結

3. 多目標擴散框架：提升腦解碼的普適性

摘要

從腦電圖（EEG）進行神經解碼仍然受到未見過的受試者之間差異大的限制，這主要是由於受試者間的高變異性和缺乏大規模數據集來有效建模。現有的方法通常依賴於合成受試者生成或簡單的數據增強，但這些策略無法可靠地擴展或普適。我們引入了一種名為\textit{MultiDiffNet}的擴散框架，通過學習一個為多目標優化的緊湊潛在空間來完全避開生成增強。我們直接從這個空間解碼，並在使用受試者和會話不重疊的評估中，實現了各種神經解碼任務的最先進的普適性。我們還策劃並發布了一個統一的基準套件，涵蓋四個逐漸複雜的EEG解碼任務（SSVEP、運動意象、P300和想像語音）以及一個解決先前EEG研究中不一致分割實踐的評估協議。最後，我們開發了一個專為低試驗EEG設計的統計報告框架。我們的工作為現實世界的腦機接口（BCI）系統中的受試者無關的EEG解碼提供了一個可重現和開源的基礎。

導讀

這篇文章介紹了一種名為MultiDiffNet的新方法，用於改善腦電圖（EEG）的神經解碼。傳統方法在面對不同受試者時，常因資料差異大而表現不佳。MultiDiffNet則使用了一種擴散框架（diffusion framework），不依賴於生成增強（generative augmentation），而是學習一個多目標優化的潛在空間（latent space），從中直接解碼，提升了普適性。此外，作者還提供了一個基準套件和評估協議，幫助研究者在不同的EEG解碼任務中進行一致的測試。

學習路徑

EEG基礎知識 → 神經解碼技術 → 機器學習基礎 → 擴散模型（Diffusion Models） → 潛在空間（Latent Space）優化 → 腦機接口（BCI）系統

原文連結

點擊連結

4. 感知圖：從腦電圖重建視覺感知與推測電極偏好

摘要

視覺神經解碼技術的進步使得從腦電圖（EEG）中重建高品質圖像成為可能，這主要得益於擴散模型（diffusion models）的應用。雖然近期的研究多著重於利用相對複雜的架構來提升從EEG中重建圖像的性能，但對於信息來源的研究卻較少。我們提出了一個統一框架，不僅能夠利用簡單的線性解碼器從EEG中重建圖像，還能隔離出支持視覺感知的可解釋EEG特徵圖。與依賴於深層且不透明模型的先前方法不同，我們的方法利用CLIP嵌入（CLIP embeddings）的內在結構，保持映射的線性。我們證明，從EEG到CLIP潛在空間訓練一個簡單的線性解碼器，接著使用預訓練且凍結的擴散模型，即可實現圖像的解碼，並達到最先進的重建性能。除了重建之外，感知圖還能夠可視化推測的電極偏好和EEG模式，揭示出對應於不同視覺屬性（如語義類別、紋理和色調）的可解釋EEG特徵圖。因此，我們利用感知圖框架來探測EEG信號在視覺信息層次結構中的不同層次。

導讀

這篇文章介紹了一種新方法，稱為「感知圖」（Perceptogram），用於從腦電圖（EEG）重建視覺圖像。傳統上，這需要複雜的深度學習模型，但感知圖使用的是一種簡單的線性解碼器（linear decoder），並結合CLIP嵌入（CLIP embeddings，一種將圖像和文字轉換為相同空間的技術）和預訓練的擴散模型（diffusion models，用於生成圖像的技術）。這不僅簡化了過程，還能揭示EEG信號中的特徵圖，這些特徵圖與視覺屬性如顏色和紋理有關。

學習路徑

神經科學基礎 → 腦電圖（EEG）原理 → 機器學習基礎 → 深度學習基礎 → CLIP模型 → 擴散模型 → 感知圖應用

原文連結

點擊連結

5. 使用人工智慧技術對尖峰信號數據進行功能分類：綜述

摘要

人類大腦神經元活動在現今具有極大的重要性。透過分析如腦電圖（EEG）等信號數據，科學家可以獲得有關疾病和人機互動的寶貴資訊。研究人員在評估這些信號時面臨的挑戰之一是大量尖峰數據的存在。尖峰是信號數據中的重要部分，可能由於重要生物標記或物理問題（如電極移動）而發生。因此，區分尖峰類型非常重要，這就是尖峰分類概念的起點。過去，研究人員是手動分類尖峰的，這種方法不夠精確，因為需要進行大量分析。因此，人工智慧（AI）被引入神經科學，協助臨床醫生正確分類尖峰。這篇綜述討論了AI在尖峰分類中的重要性和用途，著重於神經活動噪音的識別。任務分為三個主要組成部分：預處理、分類和評估。介紹了現有方法並確定其重要性。綜述還強調了需要更高效的算法。主要目標是為未來的研究提供尖峰分類的視角，並提供對所涉及的方法和問題的全面理解。這篇綜述為未來的研究整理了尖峰分類領域的資料。在這項工作中，從不同數據庫中提取了大量研究，然後使用PRISMA相關的研究指南選擇論文。接著，選擇了基於機器學習和深度學習方法進行尖峰分類的研究，並進行了有效的預處理。

導讀

尖峰信號數據是指在腦電圖（EEG）等神經信號中出現的突發性活動，這些活動可能代表重要的生物標記或由於電極移動等物理因素引起。傳統上，研究人員需要手動分析這些尖峰信號，但這種方法耗時且不夠精確。人工智慧（AI）技術的引入，尤其是機器學習和深度學習，為尖峰信號的分類提供了更高效的解決方案。這篇文章的重點在於如何利用AI技術來提高尖峰分類的準確性，並探討了現有方法的優缺點以及未來的研究方向。

學習路徑

神經科學基礎 → 腦電圖（EEG）分析 → 信號處理技術 → 機器學習基礎 → 深度學習基礎 → 尖峰信號分類技術 → 人工智慧在神經科學中的應用

原文連結

[點擊連結](#)



神經科學 / 心理學-----

白鷗 x 喚
Daily Bio Juan

6. 檢測阿茲海默症基因共表現拓撲的不連續性

摘要

阿茲海默症（AD）源於分子、細胞和網絡層面的複雜交互作用，這些交互作用難以被傳統的還原主義框架捕捉。基因表現的常規分析通常依賴於閾值相關網絡或基於聚類的模塊檢測，這些方法可能會掩蓋非線性結構和高階組織。在此，我們引入一種比較拓撲框架，利用拓撲數據分析（TDA）和Mapper算法來檢測基因共表現空間中健康與AD腦組織之間的拓撲不連續性——即局部的拓撲中斷。利用來自三個腦區的基因表現數據，我們繪製了AD如何重塑基因-基因關係的全球拓撲。通過基於變異性的節點評分識別不連續熱點，並進行基因本體生物過程富集分析。這項工作展示了TDA在高維轉錄組數據中揭示疾病相關結構的潛力，並激勵在神經退行性疾病研究和其他受益於比較分析的領域中更廣泛地應用基於形狀的比較方法。

導讀

阿茲海默症是一種由多種分子和細胞層面的變化引起的疾病，傳統的方法難以全面分析這些變化。研究者使用了一種叫做拓撲數據分析（TDA）的新方法，這是一種數學工具，用來研究數據的形狀和結構。他們使用Mapper算法來檢測基因表現中的不連續性，這些不連續性可能是健康和患病腦組織之間的重要區別。這種方法幫助研究人員更好地了解阿茲海默症如何影響基因之間的關係，並可能為未來的研究提供新的方向。

學習路徑

基因表現 → 基因共表現網絡 → 拓撲數據分析（TDA） → Mapper算法 → 阿茲海默症的分子機制
→ 基因本體生物過程分析

原文連結

點擊連結

7. 解碼抗氧化和抗炎營養補充品在中風中的科學

摘要

中風是全球致殘和死亡的主要原因，其中缺血性中風佔了近80%的病例。少於5%的患者接受了唯一經驗證的藥物治療，即靜脈溶栓療法，這突顯了對新療法的迫切需求。在這種情況下，自然分子的探索成為了一個有前途的方向，特別是作為解決傳統藥物相關限制的方法。營養補充品是從食物來源中提取的生物活性化合物，為健康和保健提供了一個引人注目的前景。這個術語反映了它們在營養和藥物治療中的雙重潛力，強調了它們在疾病預防和治療中的相關性。有趣的是，許多營養補充品最初被認為是「自然預處理劑」，即能夠使身體準備好抵禦壓力或損傷的物質。事實上，許多營養補充品已被證明能激活類似於預處理所觸發的保護途徑。特別是，來自植物或魚類的omega-3多不飽和脂肪酸和多酚類化合物被認為具有很大的潛力。它們的攝取與降低缺血性中風風險有關，並得到許多臨床前研究的支持，這些研究顯示它們對神經血管單位內細胞組件的有益影響。這篇評論探討了各種營養補充品對缺血性損傷主要驅動因素（如興奮性毒性、氧化應激、細胞凋亡和炎症）的共同保護機制。通過描述這些作用，該評論強調了營養補充品作為增強神經保護的腦預處理劑的潛力，從而在預防和治療中減輕腦缺血的影響。

導讀

中風是全球範圍內導致殘疾和死亡的重要原因，尤其是缺血性中風。傳統治療方法如靜脈溶栓療法的使用率很低，因此科學家們開始研究來自食物的生物活性化合物，即營養補充品（Nutraceuticals），來尋找新的治療方法。這些化合物如omega-3脂肪酸（來自植物或魚類的多不飽和脂肪酸）和多酚（Polyphenols），被認為能夠降低中風風險，因為它們可以激活保護性生物途徑，對抗中風造成的損傷，例如興奮性毒性（Excitotoxicity）、氧化應激（Oxidative stress）、細胞凋亡（Apoptosis）和炎症（Inflammation）。這些研究表明，營養補充品可能在預防和治療中風方面發揮重要作用。

學習路徑

營養學基礎 → 生物活性化合物 → 中風的病理生理學 → 營養補充品與中風預防 → Omega-3脂肪酸的作用機制 → 多酚的生物學效應 → 神經血管單位的功能

原文連結

[點擊連結](#)

8. 一個普遍的相圖模型用於體內蛋白質聚集

摘要

神經退行性疾病是由於在受影響個體的大腦中蛋白質聚集物的累積所驅動的。在試管內 (in vitro) 的聚集行為已被充分理解，這是由於過飽和蛋白質溶液向其聚集平衡狀態的平衡過程。然而，在活體系統中，情況發生了根本性的改變，因為活躍的過程會消耗能量來去除聚集物。目前仍不清楚細胞如何以及為什麼會從一個以單體蛋白質為主、穩定持續數十年的狀態轉變為以聚集物為主的狀態。在此，我們開發了一個簡單但通用的理論框架來描述包含聚集物形成和去除的細胞系統。使用一個二維相圖表示，我們展示了聚集物形成和去除的相互作用在細胞層面上產生雙穩態，並具有一個分岔結構，這解釋了疾病的出現以及治療干預的效果。我們探索了廣泛的聚集物形成和去除機制，並展示了當滿足機制上的最小要求時，像種子化 (seeding) 這樣的現象會穩定出現。通過將試管內聚集機制與細胞狀態的變化相連接，我們的框架提供了一個一般性的概念鏈接，將分子層級的治療干預與其對疾病進展的影響相聯繫。

導讀

這篇文章探討了神經退行性疾病中蛋白質聚集的機制。通常在試管內，蛋白質會自然聚集，但在活體內，細胞會主動消耗能量去除這些聚集物。研究者開發了一個理論模型，使用二維相圖 (phase-plane) 來描述細胞內蛋白質聚集和去除的動態，這種模型可以幫助理解疾病的發展以及治療的影響。雙穩態 (bistability) 和分岔 (bifurcation) 結構是這個模型的核心，這些概念用來解釋細胞如何在單體和聚集物狀態之間轉換。

學習路徑

細胞生物學 → 蛋白質化學 → 神經退行性疾病 → 相圖模型 → 雙穩態與分岔理論 → 分子治療學

原文連結

點擊連結

9. 強健的核心-邊緣約束變壓器於領域適應

摘要

無監督領域適應 (Unsupervised Domain Adaptation, UDA) 旨在學習跨領域的可轉移表示。近期有一些UDA研究成功應用基於變壓器 (Transformer) 的方法，並達到最新的技術成果 (state-of-the-art, SOTA)。然而，當源域和目標域之間存在較大領域差距時，仍然具有挑戰性。受到人類在將知識從熟悉領域轉移到未知領域的卓越適應能力的啟發，我們嘗試應用人類功能性大腦網絡中普遍存在的組織結構，即核心-邊緣原則 (core-periphery principle)，來設計變壓器並提升其UDA性能。在本文中，我們提出了一種新穎的、受大腦啟發的強健核心-邊緣約束變壓器 (Robust Core-Periphery Constrained Transformer, RCCT)，在多個數據集上帶來顯著的性能提升。具體而言，在RCCT中，圖像塊之間的自注意力操作由一個自適應學習的加權圖 (weighted graph) 中的核心-邊緣結構 (CP graph) 重新安排，其中圖像塊之間的信息交流和交換由學習到的加權CP圖的連接強度 (即邊緣權重) 操控和控制。此外，由於領域適應任務中的數據可能是噪聲的，為了提高模型的魯棒性，我們故意在潛在空間中對塊添加擾動，以確保生成強健的學習加權核心-邊緣圖。在多個廣泛測試的UDA基準上進行了廣泛評估。我們提出的RCCT在包括Office-Home (88.3%)、Office-31 (95.0%)、VisDA-2017 (90.7%) 和DomainNet (46.0%) 等數據集上表現始終優於現有工作。

導讀

無監督領域適應 (UDA) 是一種機器學習技術，旨在讓模型能夠在不同的數據分佈 (領域) 中進行有效的預測。傳統上，當源域和目標域之間的差異很大時，模型的性能會受到影響。這篇文章提出了一種新的方法，稱為強健核心-邊緣約束變壓器 (RCCT)，這種方法受人類大腦結構的啟發，利用核心-邊緣原則來優化變壓器的性能。RCCT通過重新安排圖像塊之間的自注意力操作，並在潛在空間中加入擾動來提高模型的魯棒性，從而在多個數據集上取得了優異的成績。

學習路徑

機器學習基礎 → 深度學習 → 變壓器模型 (Transformer) → 無監督學習 → 領域適應 (Domain Adaptation) → 核心-邊緣結構 (Core-Periphery Structure) → 強健性設計 (Robust Design)

原文連結

點擊連結

10. 深度學習在血腦屏障通透性預測中的應用

摘要

預測一個分子是否能穿過血腦屏障（BBB）是神經藥物開發早期階段的關鍵步驟，這直接影響藥物發現的研究效率和成功率。傳統基於物理化學性質的經驗方法，由於依賴靜態規則，容易出現系統性誤判。早期的機器學習模型雖然是數據驅動，但通常存在容量有限、泛化能力差和解釋性不足的問題。近年來，人工智慧（AI）方法因其能夠建模分子結構和捕捉複雜生物機制，已成為預測BBB通透性和指導相關藥物設計的重要工具。本文系統性回顧了該領域的演變，從深度神經網絡到基於圖的結構建模，強調多任務和多模態學習策略在識別機制相關變量中的優勢。我們進一步探討了生成模型和因果推斷方法在將通透性預測與機制感知藥物設計整合中的新興潛力。BBB建模正從靜態分類向機制感知和結構-功能建模轉變。這一範式轉變為AI在神經藥理學開發中的整合提供了方法論基礎和未來路線圖。

導讀

在神經藥物的開發過程中，了解一個分子是否能穿過血腦屏障（BBB）是非常重要的。傳統的方法依賴於物理和化學性質，但這些方法有時會出現誤判。早期的機器學習模型雖然使用數據來預測，但其能力有限。如今，人工智慧（AI）技術，特別是深度學習（模擬人腦的計算模型），能夠更好地預測分子的通透性。這篇文章回顧了從深度神經網絡到圖結構建模的發展，並強調多任務學習（同時學習多個相關任務）和多模態學習（使用多種數據形式）的優勢。未來，生成模型（自動生成數據的模型）和因果推斷方法（理解因果關係的技術）將在藥物設計中發揮更大作用。

學習路徑

基礎化學 → 生物化學 → 藥理學 → 機器學習基礎 → 深度學習 → 神經網絡 → 圖神經網絡 → 多任務學習 → 多模態學習 → 生成模型 → 因果推斷

原文連結

點擊連結



AI / 數據分析-----

白鷗 x 喚
Daily Bio Juan

11. 一個生態學知識驅動的深度學習框架，用於可解釋和可驗證的棲地映射

摘要

海底棲地的研究面臨著由於海床環境的複雜性、技術限制以及高昂的運營成本所帶來的挑戰，特別是在未充分探索的地區。這些挑戰導致了在水生生物資源的可持續管理及其與社會的關聯性方面的知識缺口。我們開發了一個名為ECOSAIC (Ecological Compression via Orthogonal Specialized Autoencoders for Interpretable Classification) 的人工智慧框架，旨在通過可解釋的潛在表示和可定制的自編碼器自動分類海底棲地。ECOSAIC通過優化領域知識特徵之間的專業化和正交性來壓縮n維特徵空間。我們使用了兩個領域知識類別：生物地球化學和水文地貌學，這兩者結合了生物、物理化學、水文和地貌特徵，這些特徵對棲地的限制在生態學中已被認識了一個世紀。我們將該模型應用於哥倫比亞太平洋海域，結果揭示了16種海底棲地，範圍從紅樹林延伸到深達1000米的岩石區域。候選棲地在其環境限制（在潛在空間中表示）與其預期的物種組成之間表現出強烈的對應關係。這種對應反映了有意義的生態關聯，而不是純粹的統計相關性，其中棲地的環境提供與物種的需求在語義上是一致的。這種方法可以改善海底棲地的管理和保護，促進支持海洋規劃、生物多樣性保護和魚類資源評估的功能性地圖的開發。我們也希望這能提供新的見解，說明生態學原則如何為人工智慧框架提供信息，特別是在生態研究中普遍存在數據限制的情況下。

導讀

這篇文章介紹了一種名為ECOSAIC的人工智慧框架，用於自動分類海底棲地。海底棲地的研究通常因為海床環境複雜和技術限制而困難重重。ECOSAIC通過使用自編碼器（一種神經網絡模型）來壓縮和解釋海底環境的多維特徵，從而幫助識別不同的棲地類型。這個框架特別著重於生物地球化學（研究生物與地球化學過程的交互作用）和水文地貌學（研究水體和地形的相互作用），這兩個領域的知識幫助模型更準確地理解海底棲地的特徵。研究結果顯示，這種方法可以更好地管理和保護海底棲地，並促進海洋規劃和生物多樣性保護。

學習路徑

生態學基礎 → 生物地球化學 → 水文地貌學 → 機器學習基礎 → 自編碼器 → 深度學習應用於生態學

原文連結

點擊連結

12. EscalNet：基於有效能量學習生物分子動力學的各向同性表示空間

摘要

深度學習已成為分析生物分子動力學軌跡的強大框架，能夠有效地表現系統動力學的核心，並促進機制研究。我們提出了一種神經網絡架構，結合傅立葉變換分析來處理軌跡數據，達成雙重目標：消除高頻噪音的同時保留對生物學至關重要的慢速構象動力學，並通過最後一層隱藏層建立各向同性的表示空間，以增強動力學量化。比較蛋白質模擬顯示，我們的方法比線性回歸方法產生更均勻的特徵分佈，這從更平滑的狀態相似性矩陣和更清晰的分類邊界中得到了證明。此外，通過使用顯著性得分，我們識別出與系統動力學的有效能量景觀相關的關鍵結構決定因素。我們相信，將神經網絡特徵與物理有序參數結合，創建了一個穩健的分析框架，推進生物分子軌跡分析。

導讀

這篇文章介紹了一種名為EscalNet的神經網絡架構，專門用於分析生物分子的動力學。它利用傅立葉變換（數學方法，用於將信號從時域轉換到頻域）來處理數據，從而濾除不必要的高頻噪音，但保留對生物學重要的慢速變化。這樣做的目的是建立一個各向同性（在所有方向上性質相同）的表示空間，這有助於更好地量化動力學。研究還表明，這種方法比傳統的線性回歸方法更能均勻地分佈特徵，並能更清晰地識別出與能量景觀相關的結構特徵。

學習路徑

傅立葉變換 → 深度學習 → 生物分子動力學 → 神經網絡架構 → 各向同性表示空間 → 能量景觀分析

原文連結

[點擊連結](#)

13. 學習 T 細胞抗原識別原理

摘要

T 細胞在適應性免疫反應中扮演核心角色，能夠以驚人的特異性和敏感性檢測病原體抗原，同時忽略健康組織。要定量理解 T 細胞受體（TCR）如何在抗原中進行辨別，需要生物物理模型和信號網絡的理論分析。在本文中，我們回顧了現代實驗和計算進展背景下的抗原識別理論框架。抗原效力呈現連續譜，並在複雜混合物中顯示非線性效應，這對離散分類和簡單的閾值模型構成挑戰。這種複雜性促使我們開發如自適應動力學校對這樣的模型，整合了激活和抑制信號。高通量技術的進步現已生成大規模、定量數據集，通過統計和機器學習方法來完善這些模型。理論、數據和計算的融合有望深入了解免疫決策，並為合理的免疫療法設計開闢新途徑。

導讀

T 細胞是免疫系統中負責辨別外來病原體（如細菌和病毒）與自身健康細胞的關鍵角色。T 細胞受體（TCR）是 T 細胞上的一種蛋白質，能夠識別抗原（病原體表面的特定分子）。這篇文章探討了如何利用生物物理模型和理論分析來理解 TCR 如何辨別不同的抗原。由於抗原的效力和反應是非線性的，這使得傳統的簡單模型難以準確描述，因此需要更複雜的模型來解釋這些過程。隨著高通量技術的進步，我們能夠獲得大量數據，這些數據可以用來改進模型，並可能推動新型免疫療法的開發。

學習路徑

免疫學基礎 → T 細胞生物學 → T 細胞受體（TCR）結構與功能 → 生物物理模型 → 信號傳導網絡 → 高通量技術 → 機器學習在生物學中的應用 → 免疫療法設計

原文連結

點擊連結

14. 人工智慧驅動的MALDI-TOF MS生成技術於微生物特徵分析

摘要

基質輔助雷射脫附/游離飛行時間質譜儀 (MALDI-TOF MS) 已成為臨床微生物學中的一項核心技術，能夠快速且準確地識別微生物。然而，由於缺乏足夠大、平衡且標準化的光譜數據集，數據驅動的診斷模型的開發仍然受到限制。本研究探討使用深度生成模型來合成真實的MALDI-TOF MS光譜，以克服數據稀缺問題，並支持微生物學中強大機器學習工具的開發。我們調整並評估了三種生成模型：變分自動編碼器 (MALDIVAE)、生成對抗網絡 (MALDIGAN) 和去噪擴散概率模型 (MALDIffusion)，用於依據物種標籤的條件生成微生物光譜。生成是基於物種標籤進行的，並使用多種指標評估光譜的真實性和多樣性。我們的實驗表明，MALDIVAE、MALDIGAN和MALDIffusion生成的合成數據在統計和診斷上與真實測量值相當，僅使用合成樣本訓練的分類器可以達到與使用真實數據訓練的分類器相似的性能。雖然所有模型都能忠實再現MALDI-TOF光譜的峰結構和變異性，但MALDIffusion在實現這種真實性時需要顯著更高的計算成本，而MALDIGAN則表現出競爭但稍微不穩定的行為。相比之下，MALDIVAE在真實性、穩定性和效率之間提供了最有利的平衡。此外，通過合成光譜增強少數物種顯著提高了分類準確性，有效緩解了類別不平衡和領域不匹配問題，而不損害生成數據的真實性。

導讀

基質輔助雷射脫附/游離飛行時間質譜儀 (MALDI-TOF MS) 是一種用於快速識別微生物的技術。然而，開發基於數據的診斷模型面臨著數據不足的挑戰。這篇文章研究了如何利用深度生成模型（如變分自動編碼器、生成對抗網絡和去噪擴散概率模型）來生成真實的MALDI-TOF MS光譜，從而改善微生物學中的機器學習應用。這些模型能夠生成與真實數據相似的合成光譜，並在分類器訓練中表現出色，特別是在處理類別不平衡問題時。

學習路徑

微生物學 → 質譜分析 → MALDI-TOF MS技術 → 機器學習基礎 →
深度生成模型（變分自動編碼器、生成對抗網絡、去噪擴散概率模型） → 數據增強技術

原文連結

[點擊連結](#)

15. 基於數據驅動的微流控癌細胞分離預測模型在確定性橫向位移裝置中的應用

摘要

確定性橫向位移 (Deterministic Lateral Displacement, DLD) 裝置廣泛應用於微流控技術中，用於不依賴標記、基於大小的顆粒和細胞分離，特別是在分離循環腫瘤細胞 (Circulating Tumor Cells, CTCs) 以進行早期癌症診斷方面顯示出巨大潛力。本研究專注於優化DLD設計參數，如行移位分數、柱大小和間隙距離，以增強基於物理特性的肺癌細胞選擇性分離。為克服稀有CTC檢測的挑戰並減少對計算密集型模擬的依賴，研究採用了機器學習模型，包括梯度提升、k-近鄰、隨機森林和多層感知器 (MLP) 回歸模型。這些模型在一個經數值驗證的大型數據集上進行訓練，預測顆粒軌跡並識別最佳裝置配置，從而實現高通量和低成本的DLD設計。除了軌跡預測之外，這些模型還有助於隔離關鍵設計變量，提供了一個系統的、數據驅動的自動化DLD優化框架。這種整合方法推進了可擴展且精確的微流控系統的開發，促進了早期檢測和個性化醫療的更廣泛目標。

導讀

確定性橫向位移裝置 (DLD) 是一種微流控技術，用於根據顆粒或細胞的大小進行分離，無需使用標記。這在分離循環腫瘤細胞 (CTCs) 方面特別有用，這些細胞可以用於早期癌症診斷。研究中使用的機器學習模型 (如梯度提升和隨機森林) 是一種數據分析方法，能夠從大型數據集中學習並預測顆粒的運動軌跡。這樣的預測可以幫助設計更高效的DLD裝置，從而提高分離效率並降低成本。

學習路徑

微流控技術 → 確定性橫向位移 (DLD) → 循環腫瘤細胞 (CTCs) →
機器學習模型 (梯度提升、隨機森林等) → 數據驅動設計優化

原文連結

點擊連結



微生物 / 微生態-----

白鷗 x 喚
Daily Bio Juan

16. 快速且靈活的通用圖流分解方法透過支配者

摘要

多組裝方法的核心在於解決流分解問題，具體來說，就是將加權圖分解為加權路徑或行走。然而，過去十年的大多數研究結果集中在有向無環圖（DAGs）上的分解。這一限制導致了純粹的啟發式方法，或者在應用中通過預處理啟發式方法將含有循環的圖轉換為DAG。在本文中，我們展示了流分解問題也可以在含有循環的通用圖上實際解決，通過一個框架產生快速且靈活的混合整數線性規劃（MILP）表述。我們的關鍵技術依賴於圖論中的支配樹概念，我們利用它來找到所有安全的邊序列，這些序列保證出現在任何流分解解決方案的某個行走中。我們將之前在DAG上的結果推廣到循環圖，通過展示最大安全序列對應於兩個支配樹的公共葉子的擴展，並且我們可以在其大小的線性時間內找到所有這些序列。利用這些，我們可以加速任何通用圖中流分解為行走的MILP，通過設置至少1個合適的變量來編碼解決方案行走，並設置0個其他不可達的行走變量來自和到安全序列。這減少了模型大小並消除了MILP變量乘積的昂貴線性化。我們在四個細菌數據集上實驗了三種分解模型（最小流分解、最小絕對誤差和最小路徑誤差）。我們的預處理最多能加速千倍，並在30秒內解決許多否則會超時的實例。因此，我們希望我們基於支配者的MILP簡化框架和隨附的軟體庫可以成為多組裝應用中的構建塊。

導讀

流分解問題是指將一個加權圖分解為加權路徑或行走的問題。傳統上，這個問題主要在有向無環圖（DAGs）中研究，這樣的圖不包含循環（不會形成閉合的路徑）。然而，現實中的圖通常包含循環，因此需要新的方法來處理這些通用圖。本文提出了一種新的方法，使用支配樹（dominator tree，一種圖論結構，用於分析圖的控制流）來找到安全的邊序列，這些序列可以保證出現在任何流分解的解決方案中。這樣的技術可以加速混合整數線性規劃（MILP，一種數學優化方法）在圖中的應用，尤其是在含有循環的圖中。

學習路徑

圖論基礎 → 有向無環圖（DAGs） → 支配樹（dominator tree） → 混合整數線性規劃（MILP） → 流分解問題 → 多組裝方法

原文連結

[點擊連結](#)



產業趨勢 / 法規-----

白鷗 x 喚
Daily Bio Juan

17. 基因調控網絡中的穩定化原則：從離散動態系統的視角

摘要

基因調控網絡展示出驚人的穩定性，能在基因和環境擾動下維持功能性表型。離散動態模型，如布林網絡，為系統生物學家提供了一個可處理的框架，以探索這種穩健性的數學基礎。穩定性的一個關鍵機制是管道化（canalization）。本文從歷史見解、離散動態模型中管道化的正式定義、穩定性的量化測量、應用實例以及理論與實驗交界處的新興挑戰等方面進行綜合分析。

導讀

基因調控網絡（Gene Regulatory Networks）是指基因之間相互作用的複雜系統，這些系統能夠在面對基因突變或環境變化時保持穩定。離散動態模型（Discrete Dynamical Models），如布林網絡（Boolean Networks），是一種用來模擬這些系統的數學工具。管道化（Canalization）是指系統在面對擾動時，仍然能夠保持穩定的一種機制。本文探討了這些概念的歷史背景、數學定義及其在實際應用中的挑戰。

學習路徑

基因調控網絡 → 離散動態系統 → 布林網絡 → 管道化 → 系統生物學

原文連結

[點擊連結](#)

白鷗 x 喚
Daily Bio-Fun

18. 知識引導蒸餾：無需先驗的基因調控網路推斷

摘要

基因調控網路 (Gene Regulatory Network, GRN) 推斷是解碼細胞決策過程的基石。早期的方法僅依賴基因表達數據，因此其預測能力受限於潛在基因-基因互動的巨大組合空間。隨後的方法整合先驗知識以減少這一挑戰，通過將解決方案空間限制在生物學上合理的互動中。然而，我們認為這些方法的有效性依賴於先驗信息的精確性，並且搜索空間的縮小會限制模型對新生物學發現的潛力。為了解決這些限制，我們引入KINDLE，一個三階段的框架，將GRN推斷與先驗知識依賴性分離。KINDLE訓練一個教師模型，將先驗知識與時間基因表達動態整合，隨後將此編碼知識蒸餾到一個學生模型，使其僅從表達數據中進行準確的GRN推斷，而不需任何先驗。KINDLE在四個基準數據集上達到最先進的性能。值得注意的是，它成功識別了調控小鼠胚胎發育的關鍵轉錄因子，並精確描述其功能角色。在小鼠造血幹細胞數據中，KINDLE準確預測了兩個關鍵調控因子 (Gata1和Spil) 敲除後的命運轉變結果。這些生物學驗證展示了我們框架在保持拓撲推斷精度的同時，保留了對新生物學機制發現的潛力。

導讀

基因調控網路 (GRN) 是指基因之間相互調控的網路結構，這對於理解細胞如何做出決策至關重要。傳統上，GRN的推斷依賴於基因表達數據，但這種方法面臨著龐大的可能性組合挑戰。後來的方法試圖通過使用先驗知識來縮小搜索範圍，但這也可能限制發現新知識的潛力。KINDLE是一種新方法，它不依賴先驗知識，而是通過一個三階段過程，使用教師模型和學生模型來準確推斷GRN。這樣的方法不僅提高了預測的準確性，還保留了探索新生物學機制的可能性。

學習路徑

基因表達 → 基因調控網路 (GRN) → 機器學習基礎 → 先驗知識在生物學中的應用 → 蒸餾學習 (Distillation Learning) → KINDLE框架

原文連結

點擊連結

19. CFM-GP：統一條件流匹配以學習跨細胞類型的基因擾動

摘要

理解基因擾動在不同細胞環境中的影響是功能基因組學中的一個核心挑戰，對於治療發現和精準醫學具有重要意義。單細胞技術可以高解析度地測量轉錄反應，但收集這些數據既昂貴又耗時，尤其是當需要對每種細胞類型重複測量時。現有的計算方法通常需要為每種細胞類型建立單獨的模型，限制了其可擴展性和泛化能力。我們提出了CFM-GP，一種不依賴細胞類型的基因擾動預測方法。CFM-GP學習未擾動和擾動基因表達分佈之間的連續、時間依賴性轉換，並以細胞類型為條件，允許單一模型在所有細胞類型中進行預測。與使用離散建模的先前方法不同，CFM-GP採用流匹配目標，以可擴展的方式捕捉擾動動態。我們在五個數據集上進行評估：SARS-CoV-2感染、IFN-beta刺激的PBMCs、用Panobino stat治療的膠質母細胞瘤、IFN-beta刺激下的狼瘡，以及Statefate祖細胞命運映射。CFM-GP在R平方和Spearman相關性上始終優於最先進的基準，並且通路富集分析證實了關鍵生物通路的恢復。這些結果證明了CFM-GP作為跨細胞類型基因擾動預測的可擴展解決方案的穩健性和生物學真實性。

導讀

基因擾動（基因功能的改變）在不同細胞類型中的影響是基因組學的重要研究課題。傳統方法需要為每種細胞類型建立單獨的模型，這樣做不僅耗時且難以推廣。CFM-GP是一種新方法，它能夠在不依賴特定細胞類型的情況下，預測基因擾動的效果。這是透過學習未擾動和擾動基因表達之間的轉換來實現的。CFM-GP使用流匹配（Flow Matching，一種數學方法）來捕捉擾動的動態，並在多個數據集上展示了優異的預測能力。

學習路徑

基因組學基礎 → 單細胞技術 → 基因擾動與功能基因組學 → 計算生物學 → 機器學習在生物學中的應用 → 流匹配方法

原文連結

點擊連結

20. 標題

多模態協作低秩分解器在少樣本影片領域適應中的應用

摘要

在這篇文章中，我們研究了少樣本影片領域適應（Few-Shot Video Domain Adaptation, FSVDA）這一具有挑戰性的任務。影片的多模態特性引入了獨特的挑戰，需要在少樣本情境下同時考慮領域對齊和模態協作，而這在以往的文獻中被忽略。我們觀察到，在領域轉移的影響下，每個單獨模態以及融合的多模態特徵在目標領域上的泛化性能受到限制。因為每個模態由具有不同領域轉移的多個組件耦合特徵組成，這種變異性增加了領域適應的複雜性，從而降低了多模態特徵整合的有效性。為了解決這些挑戰，我們引入了一個新的模態協作低秩分解器（Modality-Collaborative Low-Rank Decomposers, MC-LRD）框架，以分解每個模態中具有不同領域轉移水平的模態獨有和模態共享特徵，使其更易於領域對齊。MC-LRD包含多個針對每個模態的分解器和多模態分解路由器（Multimodal Decomposition Routers, MDR）。每個分解器在不同模態間漸進地共享參數。MDR用於選擇性地激活分解器以產生模態獨有和模態共享特徵。為了確保高效分解，我們分別對分解器和子路由器應用了正交去相關約束，以增強其多樣性。此外，我們提出了一種跨領域激活一致性損失，以保證相同類別的目標和源樣本在分解器的激活偏好上表現出一致性，從而促進領域對齊。大量實驗結果顯示，我們的模型在三個公共基準上相較於現有方法取得了顯著改進。

導讀

這篇文章探討了少樣本影片領域適應（FSVDA），這是一種在有限樣本下進行影片分析的技術。影片通常包含多種模態（如影像和聲音），這使得資料的領域對齊（domain alignment，指將資料從一個環境適應到另一個環境的過程）變得複雜。為了解決這個問題，作者提出了一種新的方法，稱為模態協作低秩分解器（MC-LRD），這個模型能夠有效地分解和整合不同模態的特徵。透過這種方式，可以更好地處理不同模態之間的變異性，從而提升模型在新環境中的表現。

學習路徑

多模態學習 → 領域適應 → 低秩分解 → 正交去相關 → 少樣本學習 → 影片分析技術

原文連結

點擊連結



生科基礎研究-----

白鷗 x 喚
Daily Bio Juan

21. 雙路徑知識增強對比對齊網絡用於空間解析轉錄組學

摘要

空間轉錄組學 (Spatial Transcriptomics, ST) 是一種技術，可以在保留空間背景的同時測量組織切片中的基因表達譜。這項技術揭示了局部基因表達模式和組織異質性，這對於理解疾病病因至關重要。然而，由於其高昂的成本，促使人們嘗試從整片切片圖像中預測空間基因表達。儘管最近取得了一些進展，但現有方法仍面臨重大限制，如對高層次生物學背景の利用不足、過度依賴範例檢索以及異質模態對齊不足。為了解決這些挑戰，我們提出了一種新穎的雙路徑知識增強對比對齊網絡 (DKAN)，該網絡通過生物學知識指導的方法整合組織病理學圖像和基因表達譜來預測空間解析的基因表達。具體而言，我們引入了一個有效的基因語義表示模塊，利用外部基因數據庫提供額外的生物學見解，從而增強基因表達預測。此外，我們採用了一個統一的單階段對比學習範式，無縫結合對比學習和監督學習，消除對範例的依賴，並輔以自適應加權機制。此外，我們提出了一個雙路徑對比對齊模塊，利用基因語義特徵作為動態跨模態協調器，以實現有效的異質特徵整合。通過在三個公共ST數據集上的廣泛實驗，DKAN展示了優於現有最先進模型的性能，為空間基因表達預測建立了新的基準，並為推進生物學和臨床研究提供了一個強大的工具。

導讀

空間轉錄組學 (ST) 是一種可以在組織切片中測量基因表達的技術，同時保留其空間信息。這對於理解疾病的發展和原因非常重要。然而，由於成本高昂，研究人員試圖從組織切片圖像中預測這些基因表達。現有的方法在處理這些數據時面臨一些挑戰，比如對生物學背景の利用不足和異質數據的對齊問題。為了解決這些問題，研究者們開發了雙路徑知識增強對比對齊網絡 (DKAN)，這是一種新方法，通過結合組織圖像和基因表達數據，並利用外部基因數據庫來增強預測能力。DKAN使用了一種新的學習方法，結合了對比學習（利用不同數據之間的差異來學習）和監督學習（利用標註數據來學習），並且不再依賴範例檢索。該方法在多個數據集上表現優異，為未來的生物學和臨床研究提供了新的工具。

學習路徑

基因表達 → 空間轉錄組學 (ST) → 組織病理學 → 對比學習 → 監督學習 → 異質數據整合 → 雙路徑知識增強對比對齊網絡 (DKAN)

原文連結

點擊連結

22. 大型化學反應網絡中自催化子系統的枚舉

摘要

自催化是代謝網絡中的一個重要特徵，對生物體的自我維持有著關鍵的貢獻。化學反應網絡（CRNs）的自催化子系統可以通過化學計量矩陣的子矩陣的代數條件來表徵。在本文中，我們推導了在CRN的二分König表示中支持不可約自催化系統的子圖的充分條件。在此基礎上，我們開發了一種高效的算法來枚舉自催化子網絡，並作為特例，枚舉最小自催化子網絡，即完整代謝網絡中的自催化核心。該算法同樣可以用來僅確定自催化核心。作為展示應用，我們對大腸桿菌核心代謝中的自催化進行了完整分析，並枚舉了大腸桿菌、人類紅血球和甲烷八疊球菌（古菌）完整代謝網絡中有限大小的不可約自催化子系統。這些數學和算法結果配有軟件，能夠常規分析大型CRNs中的自催化。

導讀

自催化（autocatalysis）是指一種化學反應中，生成的產物能夠促進自身的生成，這在生物體的代謝過程中非常重要。化學反應網絡（CRNs）是用來描述一系列化學反應的系統，這些反應之間可能有著複雜的相互作用。本文提出了一種算法，可以有效地找出這些網絡中的自催化子系統，特別是最小的自催化核心（最小子網絡）。研究者們還展示了這種方法在大腸桿菌等生物的代謝網絡中的應用，這對於理解生物體如何自我維持有重要意義。

學習路徑

化學反應基礎 → 化學反應網絡（CRNs） → 自催化（autocatalysis） → 代謝網絡分析 → 算法設計與應用 → 生物信息學

原文連結

點擊連結

23.

輔助基因學習：透過輔助基因選擇進行空間基因表達估計

摘要

空間轉錄組學 (Spatial transcriptomics, ST) 是一種新技術，能夠在病理組織內的個別點上觀察基因表達。ST 能夠量化組織切片中數萬個基因的表達，但在測量過程中常引入大量觀察噪音。在先前的研究中，為了確保評估的有效性，訓練和評估僅限於少數變異性高的基因，並將這些基因以外的基因排除在訓練過程之外。然而，由於基因之間可能存在共表達關係，低表達基因仍可能對評估目標的估計有所貢獻。在本文中，我們提出「輔助基因學習」 (Auxiliary Gene Learning, AGL)，通過將被忽略的基因表達估計重新定義為輔助任務，並與主要任務共同訓練。為了有效利用輔助基因，我們必須選擇一組能夠正向影響目標基因預測的輔助基因。然而，由於可能組合數量龐大，這是一個具有挑戰性的優化問題。為了解決這一挑戰，我們提出基於先驗知識的可微分 Top- k 基因選擇雙層優化方法 (Prior-Knowledge-Based Differentiable Top- k Gene Selection via Bi-level Optimization, DkGSB)，該方法通過利用先驗知識對基因進行排序，並將組合選擇問題鬆弛為可微分的 Top- k 選擇問題。實驗證實了輔助基因的有效性，並顯示該方法優於傳統的輔助任務學習方法。

導讀

空間轉錄組學 (ST) 是一種能夠在病理組織中觀察基因表達的新技術，但測量過程中常會引入噪音。傳統上，研究只針對少數變異性高的基因進行訓練和評估，忽略了其他基因的潛在貢獻。本文提出了一種新的方法，稱為輔助基因學習 (AGL)，將這些被忽略的基因重新定義為輔助任務，並與主要任務一起訓練。這需要選擇一組對目標基因預測有正面影響的輔助基因。由於可能的基因組合非常多，這是一個困難的優化問題。為了解決這個問題，研究者提出了一種基於先驗知識的可微分 Top- k 基因選擇方法 (DkGSB)，這種方法能有效地選擇對預測有利的基因組合。

學習路徑

基因表達 → 空間轉錄組學 (Spatial Transcriptomics) → 輔助基因學習 (Auxiliary Gene Learning) → 基因選擇 → 雙層優化 (Bi-level Optimization)

原文連結

點擊連結

24. 邁向開放式視覺科學發現：稀疏自編碼器的應用

摘要

科學資料庫目前包含了來自基因組學、生態學、氣候學和分子生物學的數百PB (Petabyte) 的數據，如果能夠系統化地進行大規模分析，這些數據可能揭示出未被發現的模式。語言和視覺領域的大規模弱監督數據集推動了基礎模型的發展，這些模型的內部表示能夠編碼結構（如模式、共現和統計規律），超越其訓練目標。大多數現有方法僅為預先指定的目標提取結構，它們在確認上表現出色，但不支持未知模式的開放式發現。我們探討稀疏自編碼器 (SAEs) 是否能夠從基礎模型表示中實現開放式特徵發現。我們在受控的再發現研究中評估這一問題，其中學到的SAE特徵在標準分割基準上進行語義概念對齊測試，並與強大的無標籤替代方案在概念對齊指標上進行比較。應用於生態影像時，同樣的程序在沒有分割或部分標籤的情況下揭示了細粒度的解剖結構，提供了一個具有真實驗證的科學案例研究。雖然我們的實驗專注於生態學的視覺案例研究，但該方法不受領域限制，適用於其他科學（如蛋白質、基因組學、天氣）中的模型。我們的結果表明，稀疏分解為探索科學基礎模型所學內容提供了一個實用工具，這是從確認走向真正發現的重要前提。

導讀

這篇文章討論了如何使用稀疏自編碼器 (SAEs，一種機器學習模型) 來進行開放式的科學發現。科學資料庫中有大量數據，但目前的技術多半只能確認已知的模式，而無法發現新的模式。稀疏自編碼器可以從基礎模型的表示中發現新的特徵，這意味著它能夠在沒有預先設定目標的情況下，找出數據中潛在的有趣結構。這篇研究特別在生態學的影像中進行測試，結果顯示，即使沒有明確的標籤，稀疏自編碼器也能識別出細微的解剖結構，並且這種方法可以應用到其他科學領域。

學習路徑

機器學習基礎 → 自動編碼器 (Autoencoders) → 稀疏自編碼器 (Sparse Autoencoders) → 基礎模型 (Foundation Models) → 開放式科學發現 (Open-ended Scientific Discovery)

原文連結

點擊連結

25. 重新檢視多模態生存分析：從最小-最大觀點出發

摘要

整合異質模態（如組織病理學和基因組學）對於推進生存分析至關重要，但大多數現有方法通過基於注意力的融合機制優先考慮跨模態對齊，這往往以犧牲模態特有特徵為代價。這種對對齊的過度強調導致表示崩潰和多樣性降低。在這項工作中，我們從對齊和獨特性的雙重視角重新檢視多模態生存分析，提出保留模態特有結構與實現語義一致性同樣重要。在本文中，我們介紹了一個統一的最小-最大優化框架「Together-Then-Apart (TTA)」，該框架同時建模共享和模態特有的表示。「Together」階段通過共享原型對齊嵌入來最小化語義差異，這是由不平衡的最優運輸目標引導的，該目標自適應地突出信息豐富的標記。「Apart」階段通過模態錨和對比正則化器最大化表示多樣性，保留獨特的模態信息並防止特徵崩潰。在五個TCGA基準上進行的廣泛實驗表明，TTA始終優於最先進的方法。除了經驗上的提升，我們的公式提供了一種新的理論視角，說明如何在多模態生存分析中共同實現對齊和獨特性，以達到穩健、可解釋且具有生物學意義的結果。

導讀

這篇文章探討了如何在生存分析中整合不同的數據模態（如組織病理學和基因組學）。傳統方法常常注重模態之間的對齊（alignment），但可能忽略了每個模態的特有特徵，導致信息損失。作者提出了一種新的框架「Together-Then-Apart (TTA)」，該框架在「Together」階段通過共享原型來對齊不同模態的嵌入（embedding），並在「Apart」階段利用模態錨（anchors）和對比正則化器（contrastive regularizer）來保持模態的獨特性。這種方法不僅提升了分析的準確性，還提供了一種新的理論視角來理解多模態數據的整合。

學習路徑

組織病理學 → 基因組學 → 生存分析 → 多模態數據融合 → 注意力機制 → 最優運輸理論 → 最小-最大優化 → 對比學習

原文連結

[點擊連結](#)