

每日生醫新聞報告

技術導讀與學習地圖



產出日期：2026/01/08

目錄

1. 神經科學 / 心理學-----
2. 基於gPC的神經系統穩健性分析：透過概率復現度量
3. 分層時間接收窗與零樣本時間尺度泛化在生物約束尺度不變深度網絡中的應用
4. 神經感受野、刺激空間嵌入與無尺度網絡的有效幾何
5. AI / 數據分析-----
6. 自我決定代理的數學形式化
7. 高解析度網格化季風預測的時空深度學習方法
8. 將CT掃描視為影片：使用多物件追蹤的高效顱內出血檢測
9. 淺層與深層假圖像操控定位：使用Vision Mamba與引導圖神經網絡
10. 朝向零樣本點雲配準於多樣尺度、場景與感測器設置
11. 微生物 / 微生態-----
12. 細菌趨化感測器中通道容量的表觀選擇壓力

白鷗 x 喚
Daily Bio Juan



神經科學 / 心理學-----

白鷗 x 喚
Daily Bio Juan

1. 基於gPC的神經系統穩健性分析：透過概率復現度量

摘要

神經系統通常在面對參數不確定性和變化時，仍能保持其特徵功能和信號模式，這些模式也被稱為「狀態」。對於具有已知概率分佈的不確定參數的神經模型，概率穩健性分析（PRA）使我們能夠理解和量化在何種不確定性條件下，一個狀態可以在期望中被保持。我們引入了一個新的計算框架，用於神經科學中動力系統的高效和系統化的PRA，並展示其在分析多種動力學狀態的知名神經模型中的效能：單一神經元的Hindmarsh-Rose模型和皮質柱的Jansen-Rit模型。對於一個受參數不確定性影響的模型，我們使用廣義多項式混沌（generalised polynomial chaos）來推導平均神經活動信號，然後利用這些信號來評估系統在保持當前狀態時能承受的參數不確定性量，從而量化該狀態對這種不確定性的穩健性。為了評估狀態的持續性，我們提出了新的度量，並將其應用於從平均神經活動信號獲得的復現圖。整體結果是一種新穎的、通用的計算方法，結合了復現圖分析和系統化持續性分析，以評估不確定模型參數相對於其標稱值可以變化多少，同時在期望中保持標稱狀態。我們通過概率狀態保持（PP）圖總結了PRA結果，該圖捕捉了參數不確定性對所考慮模型中動力學狀態穩健性的影響。

導讀

神經系統在面對不同變數時，常常能保持其功能和信號模式，這些模式被稱為「狀態」。研究者們試圖了解在參數不確定的情況下，這些狀態能否被保持。這篇文章介紹了一種新的計算方法，使用廣義多項式混沌（generalised polynomial chaos，一種數學技術）來分析神經系統中的動力學模型，像是Hindmarsh-Rose模型和Jansen-Rit模型。透過這種方法，研究者能夠量化這些模型在面對參數不確定性時的穩健性，並使用復現圖（一種視覺化工具）來評估狀態的持續性。最終，這項研究提供了一種新的方式來理解神經系統的穩健性。

學習路徑

神經科學基礎 → 動力系統理論 → 神經動力學模型（如Hindmarsh-Rose模型）→
概率穩健性分析（PRA）→ 廣義多項式混沌（gPC）→ 復現圖分析 → 高級數學建模技術

原文連結

點擊連結

2. 分層時間接收窗與零樣本時間尺度泛化在生物約束尺度不變深度網絡中的應用

摘要

人類認知可以整合跨越多層次時間尺度的信息。儘管大腦皮層展現了分層的時間接收窗（Temporal Receptive Windows, TRWs），局部電路卻常常顯示出異質的時間常數。為了解決這個問題，我們訓練了基於尺度不變的海馬體時間細胞的生物約束深度網絡，進行模仿語言層次結構的語言分類任務（例如，「字母」形成「單詞」）。首先，使用前饋模型（SITHCon），我們發現即使網絡在層內具有相同的時間常數譜，TRWs 的層次結構仍然自然地在各層中出現。然後，我們將這些歸納先驗轉化為生物學上合理的循環架構，SITH-RNN。訓練從通用 RNN 到這個受限子集的架構序列顯示，尺度不變的 SITH-RNN 以數量級更少的參數更快地學習，並能夠零樣本泛化到分布外的時間尺度。這些結果表明，大腦使用尺度不變的、序列的先驗——編碼「什麼」發生在「何時」——使得具有這些先驗的循環網絡特別適合描述人類認知。

導讀

這篇文章探討了如何以生物學上合理的方式模擬人類大腦處理信息的方式，特別是時間尺度上的整合。文章中提到的「時間接收窗」（Temporal Receptive Windows, TRWs）是指大腦如何在不同時間範圍內接收和處理信息。研究者使用一種名為 SITHCon 的前饋模型，發現即使在相同的時間常數下，這些窗口會自然形成層次結構。接著，他們轉向一種新的循環神經網絡架構 SITH-RNN，這種架構能夠更快速有效地學習，並且能夠在未經訓練的時間尺度上進行泛化（即零樣本泛化）。這表明大腦可能使用一種尺度不變的方式來處理「什麼」在「何時」發生的信息。

學習路徑

神經科學基礎 → 時間接收窗（Temporal Receptive Windows） → 海馬體時間細胞 →
深度學習基礎 → 前饋神經網絡（Feedforward Neural Networks） → 循環神經網絡（Recurrent Neural Networks, RNNs） → SITHCon 模型 → SITH-RNN 模型

原文連結

[點擊連結](#)

3. 神經感受野、刺激空間嵌入與無尺度網絡的有效幾何

摘要

理解感受野如何在腦網絡中出現和組織，以及神經動態如何與刺激空間耦合，對於神經科學至關重要。模型通常依賴於精細調整連接性以匹配經驗數據，這可能限制生物上的合理性。我們在此提出一種基於生理學的替代方案，其中感受野和群體層級的吸引子動態自然地從無尺度網絡的有效雙曲幾何中產生。通過將刺激空間與雙曲嵌入的邊界關聯，我們使用基於速率和脈衝的模型模擬神經動態，揭示出反映刺激空間結構的局部化活動模式，而不需要突觸的精細調整。結果顯示感受野遵循實驗觀察到的統計和性質，其大小取決於神經元的連接度。該模型在不同的刺激維度和多種模態（如方向和位置選擇性）中具有普遍性。對於在直線軌道上記錄的海馬體位置場的實驗分析支持了這些發現。此框架提供了一種新的組織原則，將網絡結構、刺激空間編碼和神經動態聯繫起來，為不同腦區的感受野形成提供了見解。

導讀

在神經科學中，感受野是指神經元對特定刺激的反應區域。這篇文章探討了感受野如何在腦網絡中自然形成，並且不需要依賴於精細的突觸調整。研究者提出了一個基於無尺度網絡（具有特定連接模式的網絡）的模型，這些網絡的雙曲幾何特性可以自然地生成感受野。這意味著神經元的反應模式與刺激空間的結構有關，並且可以在不同的感官模態中應用，如視覺中的方向選擇性和空間中的位置選擇性。這種方法為理解大腦如何組織和處理信息提供了新的視角。

學習路徑

神經科學基礎 → 神經元與感受野 → 網絡科學 → 無尺度網絡 → 雙曲幾何 → 神經動態模型

原文連結

點擊連結



AI / 數據分析-----

白鷗 x 喚
Daily Bio Juan

4. 自我決定代理的數學形式化

摘要

定義代理對於認知科學和人工智慧來說是一個極其重要的挑戰。物理學通常描述機械事件，但在這些事件與代理行為之間仍然存在著無法跨越的鴻溝。要討論代理的道德性和責任性，必須對行為進行建模；這些負責任的行為是否可以完全由物理決定論解釋一直存在爭議。儘管我們已經提出了一個物理的「代理決定論」模型，似乎超越了單純的機械事件，但我們尚未建立一個嚴格的數學形式來消除歧義。在此，我們解釋為何一個物理系統可以遵循粗粒化的代理層次決定而不違反物理定律，這是通過制定超層因果關係來實現的。一般來說，包含粗粒化的超層性不會在其底層基礎未改變的情況下改變，因此，單一的超層性無法定義超層因果關係。我們將超層因果關係定義為從超層到其底層基礎層的因果效力。雖然由多個超層函數組成的代數表達式在基礎上超層，但決定代數表達式的指數序列並不在基礎上超層。因此，該序列可以擁有獨特的動態規律，這些規律獨立於底層基礎層。這種獨立的動態創造了在超層層次的時間上先行變化能夠引起底層基礎層變化的可能性。這樣的雙重法律系統被認為對於建模自我決定代理（如人類）是有用的。

導讀

文章探討了如何從數學角度定義「自我決定代理」，這是一個在認知科學和人工智慧中非常重要的概念。通常，物理學描述的是機械性的事件，但代理行為（agent behavior）卻涉及到道德和責任，這讓單純的物理決定論顯得不夠充分。作者提出了一種新的數學模型，稱為「超層因果關係」（supervenient causation），來解釋代理行為如何在不違反物理定律的情況下發生。這種模型允許在高層次的變化可以影響到低層次的變化，這對於理解人類等自我決定的代理非常重要。

學習路徑

物理決定論 → 認知科學 → 人工智慧 → 代理行為 → 超層性（Supervenience） → 超層因果關係（Supervenient Causation） → 自我決定代理模型

原文連結

點擊連結

5. 高解析度網格化季風預測的時空深度學習方法

摘要

印度夏季季風 (Indian Summer Monsoon, ISM) 是一個重要的氣候現象，對超過十億人的農業、經濟及水資源安全有著深遠影響。傳統的長期預測方法，無論是統計還是動力學方法，主要集中於預測單一的、空間平均的季節值，缺乏對區域資源管理至關重要的空間細節。為了解決這一問題，我們引入了一種新穎的深度學習框架，將網格化季風預測重構為一個時空計算機視覺任務。我們將多變量的季前大氣和海洋場視為多通道影像序列，有效地創建了一個類似影片的輸入張量。使用85年的ERA5再分析數據作為預測因子及IMD降雨數據作為目標，我們採用卷積神經網絡 (Convolutional Neural Network, CNN) 架構，學習從季前五個月 (1月至5月) 到隨後季風季節的高解析度網格化降雨模式的複雜映射。我們的框架成功地為四個季風月份 (6月至9月) 以及總季節平均值產生了不同的預測，證明了其在季內和季節預測中的實用性。

導讀

這篇文章提出了一種新的方法來預測印度夏季季風，這是一個對印度及周邊地區非常重要的氣候現象。傳統的預測方法通常只提供一個平均值，缺乏細節。而這篇文章利用深度學習中的卷積神經網絡 (CNN，一種模仿人類視覺系統的計算模型)，將季節前的大氣和海洋數據轉換為多通道影像，類似於影片，從而提高預測的空間解析度。這種方法能夠提供更精細的區域性預測，有助於更好地管理水資源和農業生產。

學習路徑

氣候學 → 大氣科學 → 深度學習 → 卷積神經網絡 (CNN) → 時空數據分析 → 季風預測

原文連結

點擊連結

6. 將CT掃描視為影片：使用多物件追蹤的高效顱內出血檢測

摘要

在邊緣設備上自動分析體積醫學影像受到3D卷積神經網絡（CNN）高記憶體和計算需求的嚴重限制。本文開發了一個輕量級的電腦視覺框架，通過將體積電腦斷層掃描（CT）數據重新構想為連續的影片流，來調和2D檢測的效率和3D上下文的必要性。這種影片視角範式被應用於時間敏感的顱內出血（ICH）檢測任務中，使用Hemorica數據集。為了確保運行效率，我們在多個YOLO架構版本（v8, v10, v11和v12）的Nano配置中進行基準測試，選擇mAP@50最高的版本作為切片級骨幹。然後引入ByteTrack算法以在 z 軸上強制解剖一致性。為了解決影片追蹤器固有的初始化滯後問題，提出了一種混合推理策略和時空一致性過濾器，以區分真實病理與瞬時預測噪聲。獨立測試數據的實驗結果顯示，所提出的框架作為嚴格的時間驗證器，將檢測精度從基準2D檢測器的0.703提高到0.779，同時保持高靈敏度。通過以較低的計算成本近似3D上下文推理，該方法為資源受限環境（如移動中風單位和物聯網支持的遠程診所）中的實時病患優先排序提供了一種可擴展的解決方案。

導讀

這篇文章探討了一種新的方法來分析醫學影像數據，特別是CT掃描。傳統上，分析這些數據需要大量的計算資源，因為它們是3D的。然而，這篇研究提出了一種將3D CT數據轉換為類似影片的2D序列的方法，這樣可以更有效地使用計算資源。這種方法特別用於檢測顱內出血（ICH），這是一種需要快速診斷的情況。研究中使用了YOLO（You Only Look Once，一種物件檢測算法）的多個版本來進行測試，並使用ByteTrack算法來確保數據的一致性。這種方法不僅提高了檢測的精度，還降低了計算成本，特別適合於資源有限的環境中使用。

學習路徑

醫學影像基礎 → 卷積神經網絡（CNN） → YOLO物件檢測算法 → 醫學影像的2D與3D分析 → 顱內出血（ICH）檢測 → ByteTrack算法

原文連結

點擊連結

7. 淺層與深層假圖像操控定位：使用Vision Mamba與引導圖神經網絡

摘要

圖像操控定位是一項重要的研究任務，因為偽造圖像可能對社會的各個方面產生重大影響。這些圖像操控可以通過傳統的圖像編輯工具（稱為「淺層偽造」）或先進的人工智慧技術（「深層偽造」）來生成。雖然許多研究專注於淺層偽造圖像或深層偽造影片的操控定位，但很少有方法同時處理這兩種情況。在本文中，我們探討了使用深度學習網絡來定位淺層和深層偽造圖像中的操控的可行性，並提出了一種解決方案。為了精確區分真實與操控的像素，我們利用Vision Mamba網絡來提取特徵圖，清晰地描述被篡改和未觸及區域之間的邊界。為了進一步增強這種區分，我們提出了一種新穎的引導圖神經網絡（G-GNN）模塊，放大操控與真實像素之間的區別。我們的評估結果顯示，與其他先進方法相比，我們提出的方法在推理準確性上取得了更高的表現。

導讀

這篇文章探討了如何使用深度學習技術來檢測和定位圖像中的偽造部分。文章中提到的「淺層偽造」是指使用傳統工具進行的簡單圖像編輯，而「深層偽造」則是利用人工智慧技術生成的複雜偽造圖像。研究人員提出了一種使用Vision Mamba網絡和引導圖神經網絡（G-GNN）的新方法，這些技術幫助識別圖像中被篡改的部分，並且顯示出比其他方法更高的準確性。

學習路徑

圖像處理基礎 → 深度學習基礎 → 圖像操控技術（淺層偽造與深層偽造）→ 圖像操控定位技術 → Vision Mamba網絡 → 圖神經網絡（GNN）→ 引導圖神經網絡（G-GNN）

原文連結

點擊連結

8. 朝向零樣本點雲配準於多樣尺度、場景與感測器設置

摘要

一些基於深度學習的點雲配準方法在零樣本泛化（zero-shot generalization）方面存在困難，通常需要針對特定數據集進行超參數調整或重新訓練以適應新環境。我們識別出三個關鍵限制：(a) 固定的用戶定義參數（如體素大小、搜索半徑）無法在不同尺度間泛化，(b) 學習的關鍵點檢測器在跨域轉移上表現不佳，(c) 絕對坐標放大了數據集之間的尺度不匹配。為了解決這些問題，我們提出了BUFFER-X，一種無需訓練的配準框架，通過以下方式實現零樣本泛化：(a) 幾何自舉進行自動超參數估計，(b) 基於分布的最遠點採樣替代學習檢測器，(c) 補丁級坐標歸一化以確保尺度一致性。我們的方法採用分層多尺度匹配來提取局部、中等和全局感受野中的對應關係，從而在多樣環境中實現穩健配準。對於效率要求高的應用，我們引入BUFFER-X-Lite，通過提前退出策略和快速姿態求解器將總計算時間減少了43%（相對於BUFFER-X），同時保持準確性。我們在包含12個數據集的綜合基準上進行評估，涵蓋物體尺度、室內和室外場景，包括異構LiDAR配置之間的跨感測器配準。結果表明，我們的方法在不需要手動調整或事先了解測試域的情況下有效泛化。

導讀

點雲配準是指將來自不同來源的三維數據對齊到同一坐標系中。這篇文章探討了一種名為BUFFER-X的新方法，該方法不需要重新訓練模型或調整參數，就能在不同的場景和感測器設置中進行點雲配準。BUFFER-X通過自動估計參數（如體素大小）、使用最遠點採樣技術（選擇距離最遠的點來代表整體分布），以及對坐標進行歸一化來解決尺度不匹配問題。這樣的方法允許在不同環境中進行穩健的配準，並且還有一個更高效的版本BUFFER-X-Lite，適合需要快速計算的應用。

學習路徑

點雲基礎 → 深度學習 → 點雲配準技術 → 零樣本學習 → BUFFER-X框架 → BUFFER-X-Lite優化策略

原文連結

點擊連結



微生物 / 微生態-----

白鷗 x 喚
Daily Bio Juan

9. 細菌趨化感測器中通道容量的表觀選擇壓力

摘要

細菌的趨化感測將嘈雜的化學信號轉換為運動和翻滾。我們使用異質的Monod-Wyman-Changeux (MWC) 模型分析單個大腸桿菌細胞中混合的Tar/Tsr趨化受體簇的靜態感測極限。通過掃描七維參數空間，我們計算了三個感測性能指標：通道容量、有效Hill係數和動態範圍。在類似大腸桿菌的參數範圍內，我們一致觀察到通道容量的顯著局部最大值，而有效Hill係數和動態範圍則沒有表現出類似的優化。達到容量的輸入分佈是雙峰的，這意味著單個細胞通過在低濃度和高濃度範圍內取樣來最大化信息。綜合這些結果表明，在單細胞層面上，通道容量可能在大腸桿菌受體簇中被選擇。

導讀

這篇文章探討了細菌如何通過趨化感測器來處理化學信號，特別是大腸桿菌中的Tar/Tsr受體簇。研究使用了MWC模型（一種描述蛋白質如何改變形狀以響應信號的模型），並分析了多個參數對感測性能的影響。文章發現大腸桿菌可能會優化其感測系統的通道容量（信息傳輸的最大能力），而不是其他指標，如有效Hill係數（描述酶活性對底物濃度的敏感度）或動態範圍（系統能夠處理的信號範圍）。這意味著細胞可能會在不同濃度範圍內取樣，以更好地獲取信息。

學習路徑

細菌趨化 → 化學感測器 → Monod-Wyman-Changeux模型 → 通道容量 → Hill係數 → 動態範圍

原文連結

點擊連結

白鷗·喚
Daily Bio-Fun